

# Эконометрика в задачах и упражнениях

Решебник с Монте-Карло и эконометрессами

Дмитрий Борзых, Борис Демешев

7 января 2015 г.

# Глава 1

## Решения и ответы к избранным задачам

1.1. да, да, да, нет

1.2.

1.3.

1.4.

1.5.  $\hat{\alpha} + \hat{\gamma} = 0$  и  $\hat{\beta} + \hat{\delta} = 1$

1.6.

1.7.

1.8.  $\hat{\beta} = \sum x_i y_i / \sum x_i^2$

1.9.  $\hat{\beta} = \bar{y}$

1.10.  $\hat{\beta}_2 = \sum (x_i - \bar{x})(y_i - \bar{y}) / \sum (x_i - \bar{x})^2$ ,  $\hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}$

1.11.  $\hat{\beta} = \sum x_i (y_i - 1) / \sum x_i^2$

1.12.  $(300 - \hat{\beta}_1)^2 + (200 - \hat{\beta}_2)^2 + (400 - \hat{\beta}_1 - \hat{\beta}_2)^2 \rightarrow \min$

1.13.  $2 \cdot (10 - \hat{\beta})^2 + (3 - \hat{\beta})^2 \rightarrow \min$

1.14.

1.15. да, возможно. Два вытянутых облачка точек. Первое облачко даёт первую регрессию, второе — вторую. Прямая, соединяющая центры облачков, — общую.

1.16. Нет. Коэффициенты можно интерпретировать только «при прочих равных», т.е. при равных  $x$ . Из-за разных  $x$  может оказаться, что у мужчин  $\bar{y}$  меньше, чем  $\bar{y}$  для женщин.

1.17.

1.18.

1.19. Оценки МНК линейны по объясняемой переменной. Если сложить объясняемые переменные в этих двух моделях, то получится вектор из единиц. Если строить регрессию вектора из единиц на константу и  $r$ , то получатся оценки коэффициентов 1 и 0. Значит,  $\hat{\beta}_1 + \hat{\gamma}_1 = 1$ ,  $\hat{\beta}_2 + \hat{\gamma}_2 = 0$

1.20. Увеличатся в 100 раз

1.21. да

1.22.  $R^2 = 0$

1.23.  $TSS_1 = TSS_2$ ,  $R_2^2 \geq R_1^2$ ,  $ESS_2 \geq ESS_1$ ,  $RSS_2 \leq RSS_1$

1.24.

1.25.  $y_i^* = 7 + 3(y_i - \bar{y})/s_y$

2.1.

2.2.

2.3.  $c_i = c \cdot x_i$ , где  $c \neq 0$

2.4.

2.5.

2.6.

2.7.

2.8.

2.9.

2.10.

2.11.

2.12.

2.13. Через теорему Гаусса–Маркова или через условную минимизацию,  $c_i = 1/n$

2.14.

2.15.

2.16.

$$1. \hat{\beta} = \frac{\sum y_i t}{\sum t^2}$$

$$2. \mathbb{E}(\hat{\beta}) = \beta \text{ и } \text{Var}(\hat{\beta}) = \frac{\sigma^2}{\sum_{t=1}^T t^2}$$

3. Да, состоятельна

2.17. несостоятельна

2.18.

2.19. Вроде бы равносильно переносу начала координат и применению результата для регрессии без свободного члена. Должна остаться несмещенность.

2.20.

2.21. Не прав. Ковариация  $\text{Cov}(y_i, \hat{y}_i)$  зависит от  $i$ , это не одно неизвестное число, для которого можно предложить одну оценку.

2.22. формула  $\sum (y_i - \bar{y})^2 / (n - 1)$  неприменима так как  $\mathbb{E}(y_i)$  не является константой

2.23.  $R^2$  — это отношение выборочных дисперсий  $\hat{y}$  и  $y$ .

2.24. Как отсутствие систематической ошибки.

2.25. нет, нет, нет

2.26.  $RSS/\sigma^2 \sim \chi_{n-k}^2$ ,  $\mathbb{E}(RSS) = (n - k)\sigma^2$ ,  $\text{Var}(RSS) = 2(n - k)\sigma^4$ ,  $\mathbb{P}(10\sigma^2 < RSS < 30\sigma^2) \approx 0.898$

2.27.

2.28.

2.29.

2.30. Можно взять четыре наблюдения равноотстоящих по вертикали от данной прямой. Подбирая остатки, добиваемся нужного  $R^2$ .

2.31.  $\hat{\beta}_1 = -4890$  и  $\hat{\beta}_2 = 2.5$

$$X = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ \dots & \dots \\ 1 & 12 \end{bmatrix} \text{ — матрица исходных регрессоров; } \tilde{X} = \begin{bmatrix} 1 & 1 + 1994 \\ 1 & 2 + 1994 \\ \dots & \dots \\ 1 & 12 + 1994 \end{bmatrix} \text{ — матрица новых регрессоров.}$$

$$\tilde{X} = X \cdot D, \text{ где } D = \begin{bmatrix} 1 & 1994 \\ 0 & 1 \end{bmatrix}.$$

Итак, уравнение регрессии с новыми регрессорами имеет вид  $y = \tilde{X}\beta + \varepsilon$  и МНК-оценки коэффициентов равны:

$$\hat{\beta} = \left( \tilde{X}^T \tilde{X} \right)^{-1} \tilde{X}^T y = ([XD]^T [XD])^{-1} [XD]^T y = D^{-1} (X^T X)^{-1} (D^T)^{-1} D^T X^T y = D^{-1} (X^T X)^{-1} X^T y \quad (1.1)$$

$$\hat{\beta} = D^{-1} \hat{\beta}_{old} = \begin{bmatrix} 1 & -1994 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 95 \\ 2.5 \end{bmatrix} = \begin{bmatrix} -4890 \\ 2.5 \end{bmatrix}$$

2.32. Мы можем существенно упростить решение, воспользовавшись матричным представлением:

$$\tilde{\beta}_2^a = \frac{1}{n} \sum_{i=1}^n \frac{y_i}{x_i} = \frac{1}{n} \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \frac{1}{n} \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix} y \quad (1.2)$$

$$\begin{aligned} \mathbb{E} \tilde{\beta}_2^a &= \frac{1}{n} \sum_{i=1}^n \frac{\mathbb{E} y_i}{x_i} = \frac{1}{n} \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix} \begin{bmatrix} \mathbb{E} y_1 \\ \mathbb{E} y_2 \\ \vdots \\ \mathbb{E} y_n \end{bmatrix} = \\ &= \frac{1}{n} \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix} \begin{bmatrix} \beta_1 + \beta_2 x_1 \\ \beta_1 + \beta_2 x_2 \\ \vdots \\ \beta_1 + \beta_2 x_n \end{bmatrix} = \\ &= \frac{1}{n} \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix} \left[ \beta_1 \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} + \beta_2 \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \right] = \frac{\beta_1}{n} \sum_{k=1}^n \frac{1}{x_k} + \beta_2 \quad (1.3) \end{aligned}$$

Значит, смещение для первой оценки равно  $\frac{\beta_1}{n} \sum_{k=1}^n \frac{1}{x_k}$ .

$$\begin{aligned} \text{Var}(\tilde{\beta}_2^a) &= \text{Var} \left( \frac{1}{n} \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix} y \right) = \\ &= \frac{1}{n^2} \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix} \text{Var}(y) \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix}^T = \\ &= \frac{1}{n^2} \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix} \text{Var}(\varepsilon) \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix}^T = \\ &= \frac{1}{n^2} \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix} \sigma_\varepsilon^2 I \begin{bmatrix} \frac{1}{x_1} & \frac{1}{x_2} & \dots & \frac{1}{x_n} \end{bmatrix}^T = \\ &= \frac{\sigma_\varepsilon^2}{n^2} \sum_{k=1}^n \frac{1}{x_k^2} \quad (1.4) \end{aligned}$$

Перейдём ко второй оценке.

$$\tilde{\beta}_2^b = \frac{\bar{y}}{\bar{x}} = \frac{1}{\bar{x}} \frac{1}{n} \begin{bmatrix} 1 & 1 & \dots & 1 \end{bmatrix} y$$

$$\begin{aligned} \mathbb{E}\tilde{\beta}_2^b &= \frac{\bar{y}}{\bar{x}} = \frac{1}{\bar{x}} \frac{1}{n} [1 \quad 1 \quad \dots \quad 1] \mathbb{E}y = \frac{1}{\bar{x}} \frac{1}{n} [1 \quad 1 \quad \dots \quad 1] \begin{bmatrix} \beta_1 + \beta_2 x_1 \\ \beta_1 + \beta_2 x_2 \\ \vdots \\ \beta_1 + \beta_2 x_n \end{bmatrix} = \\ &= \frac{1}{\bar{x}} \frac{1}{n} [1 \quad 1 \quad \dots \quad 1] \left[ \beta_1 \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} + \beta_2 \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \right] = \\ &= \frac{1}{n} \frac{\beta_1 n}{\bar{x}} + \frac{1}{n} \frac{\beta_2 \sum x_i}{\bar{x}} = \frac{\beta_1}{\bar{x}} + \beta_2 \quad (1.5) \end{aligned}$$

Значит, смещение равно  $\frac{\beta_1}{\bar{x}}$ .

$$\begin{aligned} \text{Var}(\tilde{\beta}_2^b) &= \frac{1}{\bar{x}^2} \frac{1}{n^2} [1 \quad 1 \quad \dots \quad 1] \text{Var}(y) \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} = \\ &= \frac{1}{\bar{x}^2} \frac{1}{n^2} [1 \quad 1 \quad \dots \quad 1] \text{Var}(\varepsilon) \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} = \frac{\sigma_\varepsilon^2}{\bar{x}^2 n} \quad (1.6) \end{aligned}$$

2.33. Известно, что для парной регрессии  $t_{\beta_2}^2 = \frac{R^2}{(1-R^2)/(n-2)}$ . Поэтому из выражения  $t_{\beta_2}^2 = \frac{0.05^2}{(1-0.05^2)/(n-2)} = \frac{0.05^2(n-2)}{1-0.05^2}$  становится очевидным, что при надлежащем выборе числа наблюдений можно сделать величину  $t_{\beta_2}$  сколь угодно большой.

2.34. Пусть  $Y_i = \beta_1 + \beta_2 X_i + \varepsilon_i$ ,  $i = 1, \dots, n$ .

Тогда  $Y_i = \hat{\beta}_1 + \hat{\beta}_2 X_i + \hat{\varepsilon}_i$

$Y_i - \bar{Y} = \hat{\beta}_1 + \hat{\beta}_2(X_i - \bar{X}) + \hat{\varepsilon}_i$

$Y_i - \bar{Y} = \underbrace{\hat{\beta}_1 - \bar{Y} + \hat{\beta}_2 \bar{X}}_{=0} + \hat{\beta}_2(X_i - \bar{X}) + \hat{\varepsilon}_i$

$Y_i - \bar{Y} = \hat{\beta}_2(X_i - \bar{X}) + \hat{\varepsilon}_i$

$y_i \equiv Y_i - \bar{Y}$ ,  $i = 1, \dots, n$

$x_i \equiv X_i - \bar{X}$ ,  $i = 1, \dots, n$

$y_i = \hat{\beta}_2 x_i + \hat{\varepsilon}_i$

$\mathbf{y} = \hat{\beta}_2 \mathbf{x} + \hat{\varepsilon}$ , где  $\mathbf{y} = [y_1 \quad \dots \quad y_n]^T$ ,  $\mathbf{x} = [x_1 \quad \dots \quad x_n]^T$ ,  $\varepsilon = [\varepsilon_1 \quad \dots \quad \varepsilon_n]^T$

$\mathbf{x}^T \mathbf{y} = \hat{\beta}_2 \mathbf{x}^T \mathbf{x} + \underbrace{\mathbf{x}^T \hat{\varepsilon}}_{=0}$

$$\hat{\beta}_2 = \frac{\mathbf{x}^T \mathbf{y}}{\mathbf{x}^T \mathbf{x}} \quad (1.7)$$

Аналогично получаем, что в обратной регрессии  $X_i = \beta_3 + \beta_4 Y_i + \xi_i$ ,  $i = 1, \dots, n$

$$\hat{\beta}_4 = \frac{\mathbf{y}^T \mathbf{y}}{\mathbf{y}^T \mathbf{y}} \quad (1.8)$$

$ESS = (\hat{Y} - \bar{Y}_i)^T (\hat{Y} - \bar{Y}_i)$

Заметим, что  $\hat{Y} - \bar{Y}_i = (I - \pi)(\hat{Y} - \bar{Y}_i)$ .

Действительно,  $(I - \pi)(P - \pi) = P - \pi$ , следовательно,

$\hat{Y} - \bar{Y}_i = (P - \pi)Y = (I - \pi)(P - \pi)Y = (I - \pi)(\hat{Y} - \bar{Y}_i)$ .

Далее,  $\hat{Y} - \bar{Y}_i = (I - \pi)(\hat{Y} - \bar{Y}_i) = (I - \pi)(\hat{\beta}_1 + \hat{\beta}_2 X - \bar{Y}_i) = \hat{\beta}_2 \mathbf{x}$

Значит,  $ESS = \hat{\beta}_2^2 \mathbf{x}^T \mathbf{x}$ .

Получаем:

$$R^2 = \frac{ESS}{TSS} = \frac{\hat{\beta}_2^2 \mathbf{x}^T \mathbf{x}^{(2)}}{\mathbf{y}^T \mathbf{y}} = \frac{\mathbf{x}^T \mathbf{y}^{(2)}}{(\mathbf{x}^T \mathbf{x})(\mathbf{y}^T \mathbf{y})} = \text{Corr}^2(X, Y) \quad (1.9)$$

Заметим также, что из формул (1.7), (1.8) и (1.9) следует, что  $R^2 = \hat{\beta}_2 \hat{\beta}_4$ .

Если  $\text{Corr}^2(X, Y) = 1$ , то  $R^2 = \hat{\beta}_2 \hat{\beta}_4 = 1$ .

Отметим также, что из  $R^2 = 1$  следует, что  $\hat{\varepsilon}_1 = \dots = \hat{\varepsilon}_n = 0$  и  $\hat{\xi}_1 = \dots = \hat{\xi}_n = 0$ .

Тогда  $Y_i = \hat{\beta}_1 + \hat{\beta}_2 X_i + \underbrace{\hat{\varepsilon}_i}_{=0}$  и  $X_i = \hat{\beta}_3 + \hat{\beta}_4 Y_i + \underbrace{\hat{\xi}_i}_{=0}$ ,  $i = 1, \dots, n$ .

$$X_i = \hat{\beta}_3 + \hat{\beta}_4 Y_i = (\bar{X} - \hat{\beta}_4 \bar{Y}) + \hat{\beta}_4 Y_i = \left( \bar{X} - \frac{1}{\hat{\beta}_2} \bar{Y} \right) + \frac{1}{\hat{\beta}_2} Y_i$$

$$\hat{\beta}_2 X_i = (\hat{\beta}_2 \bar{X} - \bar{Y}) + Y_i$$

$$Y_i = (\bar{Y} - \hat{\beta}_2 \bar{X}) + \hat{\beta}_2 X_i = \hat{\beta}_1 + \hat{\beta}_2 X_i$$

Следовательно, в случае когда  $\text{Corr}^2(X, Y) = 1$ , линия парной регрессии  $Y$  на  $X$  совпадает с линией парной регрессии  $X$  на  $Y$ .

2.35. Да, если строить регрессию функции от  $y$  на функцию от  $x$ . А если строить регрессию просто  $y$  на  $x$ , то оценка наклона будет распределена симметрично около нуля.

2.36. Да, является. Любые, кроме констант.  $\text{Var}(\hat{\beta}_{2,IV}) = \sigma^2 \sum (z_i - \bar{z})^2 / (\sum (z_i - \bar{z}) x_i)^2$ .

2.37.

2.38. Вспомните про  $t$ ,  $\chi^2$ ,  $F$  распределения

2.39.  $\hat{\lambda} = RSS/(n-2)$  т.к.  $\text{Var}(\varepsilon_i) = \lambda$ . Оценка  $\hat{\beta}_2$  является несмещенной, но  $\mathbb{E}(\hat{\beta}_1) = \beta_1 + \lambda$ . Можно предложить несмещенную оценку  $\hat{\beta}'_1 = \hat{\beta}_1 - RSS/(n-2)$ .

2.40.

```
df1 <- data.frame(x = c(1,2,3,4), y = c(5,3,3,4) )
df2 <- data.frame(y = rep(df1$y,10), x = rep(df1$x,10))
m1 <- lm(data=df1, y~x)
m2 <- lm(data=df2, y~x)
library(memisc)

##
## Attaching package: 'memisc'
##
## The following object is masked from 'package:plyr':
##
##   rename
##
## The following object is masked from 'package:car':
##
##   recode
##
## The following object is masked from 'package:Hmisc':
##
##   %nin%
##
## The following objects are masked from 'package:stats':
##
##   contr.sum, contr.treatment, contrasts
##
## The following object is masked from 'package:base':
##
##   as.array
mt <- mtable(m1,m2,
  summary.stats=c("N",
    "Deviance","R-squared", "sigma", "F", "p"))
```

```
write.mtable(mt, forLaTeX=TRUE)
```

	m1	m2
(Intercept)	4.500 (1.313)	4.500*** (0.301)
x	-0.300 (0.480)	-0.300** (0.110)
N	4	40
Deviance	2.300	23.000
R-squared	0.164	0.164
sigma	1.072	0.778
F	0.391	7.435
p	0.595	0.010

3.1.  $t$ -статистики

3.2.

- Поскольку  $\frac{\hat{\sigma}_\varepsilon^2(n-k)}{\sigma_\varepsilon^2} \sim \chi^2(n-k)$ , где  $\hat{\sigma}_\varepsilon^2 = \frac{RSS}{n-k}$ ,  $k = 5$ .  $P(\chi_l^2 < \frac{\hat{\sigma}_\varepsilon^2}{\sigma_\varepsilon^2} < \chi_u^2) = 0.8$ . Преобразовав, получим  $P(\frac{\hat{\sigma}_\varepsilon^2(n-5)}{\chi_u^2} < \sigma_\varepsilon^2 < \frac{\hat{\sigma}_\varepsilon^2(n-5)}{\chi_l^2}) = 0.8$ , где  $\chi_u^2 = \chi_{n-5;0.1}^2$ ,  $\chi_l^2 = \chi_{n-5;0.9}^2$  — соответствующие квантили. По условию  $\frac{\hat{\sigma}_\varepsilon^2(n-5)}{\chi_l^2} = A = 45$ ,  $\frac{\hat{\sigma}_\varepsilon^2(n-5)}{\chi_u^2} = B = 87.942$ . Поделим  $B$  на  $A$ , отсюда следует  $\frac{\chi_u^2}{\chi_l^2} = 1.95426$ . Перебором квантилей в таблице для хи-квадрат распределения мы находим, что  $\frac{\chi_{30;0.1}^2}{\chi_{30;0.9}^2} = \frac{40.256}{20.599} = 1.95426$ . Значит,  $n-5 = 30$ , отсюда следует, что  $n = 35$ .
- $\hat{\sigma}_\varepsilon^2 = 45 \frac{\chi_u^2}{n-5} = 45 \frac{40.256}{30} = 60.384$

Решение в R:

```
df <- 1:200
a <- qchisq(0.1,df)
b <- qchisq(0.9,df)
c <- b/a
d <- 87.942/45
penalty <- (c-d)^2
df.ans <- df[which(penalty==min(penalty))]
```

Количество степеней свободы  $n-5$  должно быть равно `df.ans = 30`.

3.3.

Упорядочим нашу выборку таким образом, чтобы наблюдения с номерами с 1 по 35 относились к мужчинам, а наблюдения с номерами с 36 по 58 относились к женщинам. Тогда уравнение

$$\ln W_i = \beta_1 + \beta_2 Edu_i + \beta_3 Exp_i + \beta_4 Exp_i^2 + \beta_5 Fedu_i + \beta_6 Medu_i + \varepsilon_i, i = 1, \dots, 35 \quad (1.10)$$

соответствует регрессии, построенной для подвыборки из мужчин, а уравнение

$$\ln W_i = \gamma_1 + \gamma_2 Edu_i + \gamma_3 Exp_i + \gamma_4 Exp_i^2 + \gamma_5 Fedu_i + \gamma_6 Medu_i + \varepsilon_i, i = 36, \dots, 58 \quad (1.11)$$

соответствует регрессии, построенной для подвыборки из женщин. Введем следующие переменные:

$$d_i = \begin{cases} 1, & \text{если } i\text{-ое наблюдение соответствует мужчине,} \\ 0, & \text{в противном случае;} \end{cases}$$

$$dum_i = \begin{cases} 1, & \text{если } i\text{-ое наблюдение соответствует женщине,} \\ 0, & \text{в противном случае.} \end{cases}$$

Рассмотрим следующее уравнение регрессии:

$$\begin{aligned} \ln W_i = & \beta_1 d_i + \gamma_1 dum_i + \beta_2 Edu_i d_i + \gamma_2 Edu_i dum_i + \beta_3 Exp_i d_i + \\ & \gamma_3 Exp_i dum_i + \beta_4 Exp_i^2 d_i + \gamma_4 Exp_i^2 dum_i + \beta_5 Fedu_i d_i + \gamma_5 Fedu_i dum_i + \\ & \beta_6 Medu_i d_i + \gamma_6 Medu_i dum_i + \varepsilon_i, i = 1, \dots, 58 \end{aligned} \quad (1.12)$$

Гипотеза, которую требуется проверить в данной задаче, имеет вид

$$H_0 : \begin{cases} \beta_1 = \gamma_1, \\ \beta_2 = \gamma_2, \\ \dots \\ \beta_6 = \gamma_6 \end{cases} \quad H_1 : |\beta_1 - \gamma_1| + |\beta_2 - \gamma_2| + \dots + |\beta_6 - \gamma_6| > 0.$$

Тогда регрессия

$$\begin{aligned} \ln W_i = & \beta_1 d_i + \gamma_1 dum_i + \beta_2 Edu_i d_i + \gamma_2 Edu_i dum_i + \beta_3 Exp_i d_i + \\ & \gamma_3 Exp_i dum_i + \beta_4 Exp_i^2 d_i + \gamma_4 Exp_i^2 dum_i + \beta_5 Fedu_i d_i + \\ & \gamma_5 Fedu_i dum_i + \beta_6 Medu_i d_i + \gamma_6 Medu_i dum_i + \varepsilon_i, i = 1, \dots, 58 \end{aligned} \quad (1.13)$$

по отношению к основной гипотезе  $H_0$  является регрессией без ограничений, а регрессия

$$\begin{aligned} \ln W_i = & \beta_1 + \beta_2 Edu_i + \beta_3 Exp_i + \beta_4 Exp_i^2 + \\ & \beta_5 Fedu_i + \beta_6 Medu_i + \varepsilon_i, i = 1, \dots, 58 \end{aligned} \quad (1.14)$$

является регрессией с ограничениями.

Кроме того, для решения задачи должен быть известен следующий факт:

$RSS_{UR} = RSS_1 + RSS_2$ , где  $RSS_{UR}$  — это сумма квадратов остатков в модели:

$$\begin{aligned} \ln W_i = & \beta_1 d_i + \gamma_1 dum_i + \beta_2 Edu_i d_i + \gamma_2 Edu_i dum_i + \beta_3 Exp_i d_i + \\ & \gamma_3 Exp_i dum_i + \beta_4 Exp_i^2 d_i + \gamma_4 Exp_i^2 dum_i + \beta_5 Fedu_i d_i + \\ & \gamma_5 Fedu_i dum_i + \beta_6 Medu_i d_i + \gamma_6 Medu_i dum_i + \varepsilon_i, i = 1, \dots, 58 \end{aligned} \quad (1.15)$$

$RSS_1$  — это сумма квадратов остатков в модели:

$$\begin{aligned} \ln W_i = & \beta_1 + \beta_2 Edu_i + \beta_3 Exp_i + \beta_4 Exp_i^2 + \\ & \beta_5 Fedu_i + \beta_6 Medu_i + \varepsilon_i, i = 1, \dots, 35 \end{aligned} \quad (1.16)$$

$RSS_2$  — это сумма квадратов остатков в модели:

$$\begin{aligned} \ln W_i = & \gamma_1 + \gamma_2 Edu_i + \gamma_3 Exp_i + \gamma_4 Exp_i^2 + \\ & \gamma_5 Fedu_i + \gamma_6 Medu_i + \varepsilon_i, i = 36, \dots, 58 \end{aligned} \quad (1.17)$$

1. Тестовая статистика:

$$T = \frac{(RSS_R - RSS_{UR})/q}{RSS_{UR}/(n - m)},$$

где  $RSS_R$  — сумма квадратов остатков в модели с ограничениями;

$RSS_{UR}$  — сумма квадратов остатков в модели без ограничений;

$q$  — число линейно независимых уравнений в основной гипотезе  $H_0$ ;

$n$  — общее число наблюдений;

$m$  — число коэффициентов в модели без ограничений



2. Распределение тестовой статистики при верной  $H_0$ :

$$T \sim F(q, n - m)$$

3. Наблюдаемое значение тестовой статистики:

$$T_{obs} = \frac{(70.3 - (34.4 + 23.4))/6}{(34.4 + 23.4)/(58 - 12)} = 1.66$$

4. Область, в которой  $H_0$  не отвергается:

$$[0; T_{cr}] = [0; 2.3]$$

5. Статистический вывод:

Поскольку  $T_{obs} \in [0; T_{cr}]$ , то на основе имеющихся данных мы не можем отвергнуть гипотезу  $H_0$  в пользу альтернативной  $H_1$ . Следовательно, имеющиеся данные не противоречат гипотезе об отсутствии дискриминации на рынке труда между мужчинами и женщинами.

3.4.

3.5.

3.6.

3.7.

3.8.

3.9.

3.10. Смысл гипотезы: летом и осенью одинаковая зависимость и одинаковая зависимость зимой и весной. Ограниченная модель:  $\widehat{\ln Q} = \hat{\beta}_1 + \hat{\beta}_2 \cdot \ln P + \hat{\beta}_3 d$ , где  $d$  равна 1 для лета и осени. Наблюдаемое значение статистики  $F_{obs} = 1.375$ , критическое,  $F_{cr} = 3.5219$ . Гипотеза не отвергается.

3.11.

3.12.

3.13.

3.14.

3.15.

3.16.

3.17.

3.18.

3.19. значим

3.20. не значим

3.21.  $\alpha > 0.09$

3.22.

3.23.

3.24.

Ограниченная модель (Restricted model):

$$\ln W_i = \beta + \beta_{Edu} Edu_i + \beta_{Age} Age_i + \beta_{Age^2} Age_i^2 + \varepsilon_i$$

Неограниченная модель (Unrestricted model):

$$\ln W_i = \beta + \beta_{Edu} Edu_i + \beta_{Age} Age_i + \beta_{Age^2} Age_i^2 + \beta_{Fedu} Fedu_i + \beta_{Medu} Medu_i + \varepsilon_i \quad (1.18)$$

По условию  $ESS_R = 90.3$ ,  $RSS_R = 60.4$ ,  $TSS = ESS_R + RSS_R = 90.3 + 60.4 = 150.7$ . Также сказано, что  $ESS_{UR} = 110.3$ . Значит,  $RSS_{UR} = TSS - ESS_{UR} = 150.7 - 110.3 = 40.4$

## 1. Спецификация:

$$\ln W_i = \beta + \beta_{Edu} Edu_i + \beta_{Age} Age_i + \beta_{Age^2} Age_i^2 + \beta_{Fedu} Fedu_i + \beta_{Medu} Medu_i + \varepsilon_i \quad (1.19)$$

## 2. Проверка гипотезы

- (a)  $H_0 : \begin{cases} \beta_{Fedu} = 0 \\ \beta_{Medu} = 0 \end{cases} \quad H_a : |\beta_{Fedu}| + |\beta_{Medu}| > 0$
- (b)  $T = \frac{(RSS_R - RSS_{UR})/q}{RSS_{UR}/(n-k)}$ , где  $q = 2$  — число линейно независимых уравнений в основной гипотезе  $H_0$ ,  $n = 25$  — число наблюдений,  $k = 6$  — число коэффициентов в модели без ограничения
- (c)  $T \sim F(q; n - k)$
- (d)  $T_{obs} = \frac{(RSS_R - RSS_{UR})/q}{RSS_{UR}/(n-k)} = \frac{(60.4 - 40.4)/2}{40.4/(25-6)} = 4.70$
- (e) Нижняя граница = 0, верхняя граница = 3.52
- (f) Поскольку  $T_{obs} = 4.70$ , что не принадлежит промежутку от 0 до 3.52, то на основе имеющихся данных можно отвергнуть основную гипотезу на уровне значимости 5%. Таким образом, образование родителей существенно влияет на заработную плату.

3.25.

3.26.

3.27.

3.28.

3.29.

3.30.

3.31.  $0.25\hat{\beta}_1 + 0.75\hat{\beta}'_1$ ,  $0.25\hat{\beta}_2 + 0.75\hat{\beta}'_2$  и  $0.25\hat{\beta}_3 + 0.75\hat{\beta}'_3$ 

3.32. Сами оценки коэффициентов никак детерминистически не связаны, но при большом размере подвыборки примерно равны. А дисперсии связаны соотношением  $\text{Var}(\hat{\beta}_a)^{-1} + \text{Var}(\hat{\beta}_b)^{-1} = \text{Var}(\hat{\beta}_{tot})^{-1}$

3.33.

3.34.

3.35.

3.36.

3.37.

3.38.

Из оценки ковариационной матрицы находим, что  $se(\hat{\beta}_{totsp} = \hat{\beta}_{livesp}) = 0.2696$ .

Исходя из  $Z_{crit} = 1.96$  получаем доверительный интервал,  $[-0.8221; 0.2348]$ .

Вывод: при уровне значимости 5% гипотеза о равенстве коэффициентов не отвергается.

3.39.

3.40.

3.41.

$$1. \mathbb{P}(\hat{\beta}_3 > se(\hat{\beta}_3)) = \mathbb{P}(t_{17} > 1) = 0.1657$$

$$2. \mathbb{P}(\hat{\beta}_3 > \sigma_{\hat{\beta}_3}) = \mathbb{P}(N(0, 1) > 1) = 0.1587$$

3.42. В обоих случаях можно так подобрать коэффициенты  $\hat{\beta}$ , что  $kr_i = \widehat{kr}_i$ . А именно, идеальные прогнозы достигаются при  $\hat{\beta}_{p_1} = 1$ ,  $\hat{\beta}_{p_2} = 1$ ,  $\hat{\beta}_{p_3} = 1$ ,  $\hat{\beta}_{p_4} = 1$ ,  $\hat{\beta}_{p_5} = 1$  и (в первой модели)  $\hat{\beta}_1 = 0$ . Отсюда  $RSS = 0$ ,  $ESS = TSS$ , поэтому  $R^2 = 1$  даже в модели без свободного члена. Получаем  $\hat{\sigma}^2 = 0$ , поэтому строго говоря  $t$  статистики и  $P$ -значения не существуют из-за деления на ноль.

На практике при численной минимизации  $RSS$  оказывается, что  $t$ -статистики коэффициентов при задачах принимают очень большие значения, а соответствующие  $P$ -значения крайне близки к нулю. В

первой модели особенной на практике будет  $t$  статистика свободного члена. В силу неопределенности вида  $0/0$  свободный коэффициент на практике может оказаться незначим.

3.43.

3.44.  $\hat{\beta}_2 = 0.41$ ,  $\hat{\beta}_3 = 0.3$ ,  $\hat{\beta}_4 = -0.235$ , переменная  $x$  значима

3.45.  $\hat{\beta}_2 = 0.75$ ,  $\hat{\beta}_3 = 0.625$ ,  $\hat{\beta}_4 = 0.845$ , переменные  $z$  и  $w$  значимы

3.46.  $RSS_1 > RSS_2 = RSS_3$ , в моделях два и три, ошибка прогноза равна  $\hat{\beta}_4$

3.47.

3.48.  $RSS/\sigma^2 \sim \chi^2_{n-k}$ ,  $\mathbb{E}(RSS) = (n-k)\sigma^2$ ,  $\text{Var}(RSS) = 2(n-k)\sigma^4$ ,  $\mathbb{P}(5\sigma^2 < RSS < 10\sigma^2) \approx 0.451$

3.49.  $\mathbb{P}(\hat{s}_3^2 > \hat{s}_1^2) = 0.5$ ,  $\mathbb{P}(\hat{s}_1^2 > 2\hat{s}_2^2) = 0.5044$ ,  $\mathbb{E}(\hat{s}_2^2/\hat{s}_1^2) = 1.25$ ,  $\text{Var}(\hat{s}_2^2/\hat{s}_1^2) = 4.6875$

3.50. 90% во всех пунктах

3.51. Поскольку  $\hat{\mu}$ ,  $\hat{\nu}$ ,  $\hat{\gamma}$  и  $\hat{\delta}$  являются МНК-коэффициентами в регрессии  $y_i = \mu + \nu x_i + \gamma d_i + \delta x_i d_i + \varepsilon_i$ ,  $i = 1, \dots, n$ , то для любых  $\mu$ ,  $\nu$ ,  $\gamma$  и  $\delta$  имеет место

$$\sum_{i=1}^n (y_i - \hat{\mu} - \hat{\nu}x_i - \hat{\gamma}d_i - \hat{\delta}x_i d_i - \varepsilon_i)^2 \leq \sum_{i=1}^n (y_i - \mu - \nu x_i - \gamma d_i - \delta x_i d_i - \varepsilon_i)^2 \quad (1.20)$$

Перепишем неравенство (1.20) в виде

$$\sum_{i=1}^m (y_i - (\hat{\mu} + \hat{\gamma}) - (\hat{\nu} + \hat{\delta})x_i)^2 + \sum_{i=m+1}^n (y_i - \hat{\mu} - \hat{\nu}x_i)^2 \leq \sum_{i=1}^m (y_i - (\mu + \gamma) - (\nu + \delta)x_i)^2 + \sum_{i=m+1}^n (y_i - \mu - \nu x_i)^2 \quad (1.21)$$

Учитывая, что неравенство (1.21) справедливо для всех  $\mu$ ,  $\nu$ ,  $\gamma$  и  $\delta$ , то оно останется верным для  $\mu = \hat{\mu}$ ,  $\nu = \hat{\nu}$  и произвольных  $\gamma$  и  $\delta$ . Имеем

$$\sum_{i=1}^m (y_i - (\hat{\mu} + \hat{\gamma}) - (\hat{\nu} + \hat{\delta})x_i)^2 + \sum_{i=m+1}^n (y_i - \hat{\mu} - \hat{\nu}x_i)^2 \leq \sum_{i=1}^m (y_i - (\hat{\mu} + \gamma) - (\hat{\nu} + \delta)x_i)^2 + \sum_{i=m+1}^n (y_i - \hat{\mu} - \hat{\nu}x_i)^2 \quad (1.22)$$

Следовательно

$$\sum_{i=1}^m (y_i - (\hat{\mu} + \hat{\gamma}) - (\hat{\nu} + \hat{\delta})x_i)^2 \leq \sum_{i=1}^m (y_i - (\hat{\mu} + \gamma) - (\hat{\nu} + \delta)x_i)^2 \quad (1.23)$$

Обозначим  $\tilde{\beta}_1 := \hat{\mu} + \gamma$  и  $\tilde{\beta}_2 := \hat{\nu} + \delta$ . В силу произвольности  $\gamma$  и  $\delta$  коэффициенты  $\tilde{\beta}_1$  и  $\tilde{\beta}_2$  также произвольны. тогда для любых  $\tilde{\beta}_1$  и  $\tilde{\beta}_2$  выполнено неравенство:

$$\sum_{i=1}^m (y_i - (\hat{\mu} + \hat{\gamma}) - (\hat{\nu} + \hat{\delta})x_i)^2 \leq \sum_{i=1}^m (y_i - \tilde{\beta}_1 - \tilde{\beta}_2 x_i)^2$$

которое означает, что  $\hat{\mu} + \hat{\gamma}$  и  $\hat{\nu} + \hat{\delta}$  являются МНК-оценками коэффициентов  $\beta_1$  и  $\beta_2$  в регрессии  $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$ , оцененной по наблюдениям  $i = 1, \dots, m$ , то есть  $\hat{\beta}_1 = \hat{\mu} + \hat{\gamma}$  и  $\hat{\beta}_2 = \hat{\nu} + \hat{\delta}$ .

3.52. не верно, поскольку  $R_{adj}^2$  может принимать отрицательные значения, а  $F(n-k, n-1)$  — не может.

3.53. Сгенерировать сильно коррелированные  $x$  и  $z$

3.54.

3.55.

3.56.

3.57. bootstrap, дельта-метод.

3.58.

3.59.

3.60. При наличии ошибок в измерении зависимой переменной оценки остаются несмещенными, их дисперсия растет. Однако оценка дисперсии может случайно оказаться меньше. Например, могло случиться, что ошибки  $u_i$  случайно компенсировали  $\varepsilon_i$ .

3.61.

3.62.

3.63. 0

3.64. Проводим тест Чоу

3.65. Несмещенной является  $\hat{\sigma}^2$ , поэтому  $\hat{\sigma}$  смещена, но состоятельна.

4.1.

1. В случае нестохастических регрессоров:

Пусть дана регрессионная модель  $y = X\beta + \epsilon$  с  $k$  регрессорами, включая свободный член и  $n$  наблюдениями, тогда если

(a) регрессионная модель правильно специфицирована

(b)  $\text{rang}(X) = k$

(c)  $X$  не являются стохастическими

(d)  $\mathbb{E}(\epsilon) = 0$

(e)  $\text{Var}(\epsilon) = \sigma^2 I$

то  $\hat{\beta} = (X'X)^{-1}X'y$  являются лучшими оценками в классе линейных несмещённых оценок, то есть BLUE-оценками.

В случае стохастических регрессоров:

Пусть дана регрессионная модель  $y = X\beta + \epsilon$  с  $k$  регрессорами, включая свободный член и  $n$  наблюдениями, тогда если

(a) регрессионная модель правильно специфицирована

(b)  $\text{rang}(X) = k$

(c)  $\mathbb{E}(\epsilon|X) = 0$

(d)  $\text{Var}(\epsilon|X) = \sigma^2 I$

то  $\hat{\beta} = (X'X)^{-1}X'y$  являются лучшими оценками в классе линейных несмещённых оценок, то есть BLUE-оценками.

2. Да, верно. В самом деле,

$$\begin{aligned}\mathbb{E}(\hat{\beta}) &= \mathbb{E}((X'X)^{-1}X'y) = (X'X)^{-1}X'\mathbb{E}(y) = (X'X)^{-1}X'\mathbb{E}(X\beta + \epsilon) = \\ &= (X'X)^{-1}X'X\mathbb{E}(\beta) + (X'X)^{-1}X'\underbrace{\mathbb{E}(\epsilon)}_{=0} = \beta\end{aligned}$$

3.

$$\begin{aligned}\text{Var}(\hat{\beta}) &= \text{Var}((X'X)^{-1}X'y) = (X'X)^{-1}X'\text{Var}(y)((X'X)^{-1}X')' = \\ &= (X'X)^{-1}X'\text{Var}(X\beta + \epsilon)X(X'X)^{-1}\end{aligned}$$

Так как  $\beta$  является константой, то  $\text{Var}(X\beta) = 0$ . Тогда

$$\begin{aligned}\text{Var}(\hat{\beta}) &= (X'X)^{-1}X'\text{Var}(X\beta + \epsilon)X(X'X)^{-1} = \\ &= (X'X)^{-1}X'\text{Var}(\epsilon)X(X'X)^{-1} = (X'X)^{-1}X'\sigma^2X(X'X)^{-1} = \\ &= \sigma^2(X'X)^{-1}X'X(X'X)^{-1} = \sigma^2(X'X)^{-1}\end{aligned}$$

4.2. Да, в общем случае (кроме случая  $\beta = 0$  это верно. Так как  $\tilde{\beta}$  является несмещённой, то  $\mathbb{E}(\tilde{\beta}) = \beta$ .

$$\begin{aligned}\mathbb{E}(\tilde{\beta}) &= \mathbb{E}(((X'X)^{-1}X' + A)y) = \mathbb{E}(((X'X)^{-1}X' + A)(X\beta + \epsilon)) = \\ &= \mathbb{E}(((X'X)^{-1}X' + A)X\beta) + ((X'X)^{-1}X' + A)\underbrace{\mathbb{E}(\epsilon)}_{=0} = \\ &= \mathbb{E}((X'X)^{-1}X'X\beta + AX\beta) = \beta + AX\beta\end{aligned}$$

$$\mathbb{E}(\tilde{\beta}) = \beta$$

$$\beta + AX\beta = \beta$$

$$AX\beta = 0$$

Значит, либо  $AX = 0$ , либо  $\beta = 0$ .

Заметим, что при  $\beta = 0$  при любом  $AX$  оценка  $\tilde{\beta}$  будет несмещённой.

4.3.

$$X'X = \begin{pmatrix} 3 & 2 \\ 2 & 2 \end{pmatrix}$$

$$(X'X)^{-1} = \begin{pmatrix} 1 & -1 \\ -1 & 1.5 \end{pmatrix}$$

$$\text{Var}(\hat{\beta}_1) = \text{Var}(\hat{\beta})_{[1,1]} = \sigma^2$$

$$\text{Var}(\hat{\beta}_2) = \text{Var}(\hat{\beta})_{[2,2]} = 1.5\sigma^2$$

$$\text{Cov}(\hat{\beta}_1, \hat{\beta}_2) = \text{Var}(\hat{\beta})_{[1,2]} = -\sigma^2$$

$$\text{Corr}(\hat{\beta}_1, \hat{\beta}_2) = \frac{\text{Cov}(\hat{\beta}_1, \hat{\beta}_2)}{\sqrt{\text{Var}(\hat{\beta}_1)} \sqrt{\text{Var}(\hat{\beta}_2)}} = \frac{\sigma^2}{\sigma \cdot \sqrt{1.5}\sigma} = \sqrt{\frac{2}{3}} = \frac{\sqrt{6}}{3}$$

Показательно, что значения  $y$  здесь не используются.

Ответ:  $\frac{\sqrt{6}}{3}$ .

4.4.

$$\hat{\beta} = (X'X)^{-1}X'y$$

$$X'X\hat{\beta} = X'y$$

$$\hat{\alpha} = (D'X'XD)^{-1}D'X'y$$

поэтому

$$\hat{\alpha} = (D'X'XD)^{-1}D'X'y = (D'X'XD)^{-1}D'X'X\hat{\beta} = (D'X'XD)^{-1}D'X'XDD^{-1}\hat{\beta} = D^{-1}\hat{\beta}$$

$$D^{-1} = \begin{pmatrix} 1 & -1 & 1 \\ 0 & 1 & -1 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\begin{cases} \hat{\alpha}_1 = \beta_1 - \beta_2 + \beta_3 \\ \hat{\alpha}_2 = \beta_2 - \beta_3 \\ \hat{\alpha}_3 = \beta_3 \end{cases}$$

4.5.

$$\begin{aligned}\hat{\beta} &= (X'X)^{-1}X'y \\ X'X\hat{\beta} &= X'y \\ \hat{\alpha} &= (D'X'XD)^{-1}D'X'y\end{aligned}$$

поэтому

$$\hat{\alpha} = (D'X'XD)^{-1}D'X'y = (D'X'XD)^{-1}D'X'X\hat{\beta} = (D'X'XD)^{-1}D'X'XDD^{-1}\hat{\beta} = D^{-1}\hat{\beta}$$

$$D^{-1} = \begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\begin{cases} \hat{\alpha}_1 = \beta_1 - \beta_2 \\ \hat{\alpha}_2 = \beta_2 - \beta_3 \\ \hat{\alpha}_3 = \beta_3 \end{cases}$$

4.6.

$$\begin{aligned}\hat{\beta} &= (X'X)^{-1}X'y \\ X'X\hat{\beta} &= X'y \\ \hat{\alpha} &= (D'X'XD)^{-1}D'X'y\end{aligned}$$

поэтому

$$\hat{\alpha} = (D'X'XD)^{-1}D'X'y = (D'X'XD)^{-1}D'X'X\hat{\beta} = (D'X'XD)^{-1}D'X'XDD^{-1}\hat{\beta} = D^{-1}\hat{\beta}$$

$$D^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & -1 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\begin{cases} \hat{\alpha}_1 = \beta_1 \\ \hat{\alpha}_2 = \beta_2 - \beta_3 \\ \hat{\alpha}_3 = \beta_3 \end{cases}$$

4.7. Да, верно.

$$\begin{aligned}\varepsilon'\hat{y} &= (y - \hat{y})'\hat{y} = (y - X\hat{\beta})'X\hat{\beta} = (y - X(X'X)^{-1}X'y)'X(X'X)^{-1}X'y = \\ &= ((I - X(X'X)^{-1}X')y)'X(X'X)^{-1}X'y = y'(I - X(X'X)^{-1}X')X(X'X)^{-1}X'y = \\ &= y'(X(X'X)^{-1}X' - X(X'X)^{-1}X'X(X'X)^{-1}X')y = y'(X(X'X)^{-1}X' - X(X'X)^{-1}X')y = 0\end{aligned}$$

Да, верно.

$$\hat{y}'\hat{\varepsilon} = (\varepsilon'\hat{y})' = 0$$

так как выше доказано, что  $he'\hat{y} = 0$ .

4.8.

1.

$$\hat{\gamma} = (Z'Z)^{-1}Z'y = A^{-1}(X'X)^{-1}(A')^{-1}A'X'y =$$

$$A^{-1}(X'X)^{-1}X'y = A^{-1}\hat{\beta} \quad (1.24)$$

$$2. \hat{u} = y - Z\hat{\gamma} = y - XAA^{-1}\hat{\beta} = y - X\hat{\beta} = \hat{\varepsilon}$$

3. Пусть  $z^0 = (1 \quad z_1^0 \quad \dots \quad z_{k-1}^0)$  — вектор размера  $1 \times k$  и  $x^0 = (1 \quad x_1^0 \quad \dots \quad x_{k-1}^0)$  — вектор размера  $1 \times k$ . Оба эти вектора представляют собой значения факторов. Тогда  $z^0 = x^0 A$  и прогнозное значение для регрессии с преобразованными факторами равно  $z^0 \hat{\gamma} = x^0 A A^{-1} \hat{\beta} = x^0 \hat{\beta}$  прогнозному значению для регрессии с исходными факторами.

4.9.

1.

$$\mathbb{E}(\tilde{\beta}) = ((X'X)^{-1} + \gamma I)X'\mathbb{E}(y) = ((X'X)^{-1} + \gamma I)X'X\beta = \beta + \gamma X'X\beta \quad (1.25)$$

2.

$$\begin{aligned} \text{Var}(\tilde{\beta}) &= \text{Var}(((X'X)^{-1} + \gamma I)X'y) = \\ &= \text{Var}(((X'X)^{-1} + \gamma I)X'\varepsilon) = \\ &= (((X'X)^{-1} + \gamma I)X') \text{Var}(\varepsilon) (((X'X)^{-1} + \gamma I)X')' = \\ &= (((X'X)^{-1} + \gamma I)X') \sigma_\varepsilon^2 I (((X'X)^{-1} + \gamma I)X')' = \\ &= \sigma_\varepsilon^2 ((X'X)^{-1} + \gamma I)X'X((X'X)^{-1} + \gamma I) = \\ &= \sigma_\varepsilon^2 ((X'X)^{-1} + \gamma I)(I + \gamma X'X) = \\ &= \sigma_\varepsilon^2 ((X'X)^{-1} + 2\gamma I + \gamma^2 X'X) \quad (1.26) \end{aligned}$$

4.10. Да, верно.

$$\begin{aligned} R^2 &= \frac{ESS}{TSS} = \frac{TSS - RSS}{TSS} = 1 - \frac{RSS}{TSS} \\ TSS &= \sum_{i=1}^n (y_i - \bar{y})^2 = y' \left( I - \frac{\vec{1}\vec{1}'}{\vec{1}'\vec{1}} \right) y \end{aligned}$$

не зависит от  $X$ .

$$RSS_a = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = y'(I - X(X'X)^{-1}X')y$$

$$RSS_b = y'(I - Z(Z'Z)^{-1}Z')y = y'(I - XD(D'X'XD)^{-1}D'X')y =$$

так как  $D$  является квадратной и невырожденной, то используя формулу  $(AB)^{-1} = B^{-1}A^{-1}$ , получим:

$$\begin{aligned} RSS_b &= y'(I - XD(D'X'XD)^{-1}D'X')y = y'(I - XDD^{-1}(X'X)^{-1}D'^{-1}D'X')y = \\ &= y'(I - X(X'X)^{-1}X')y = RSS_a \end{aligned}$$

Значит,

$$R_a^2 = 1 - \frac{RSS_a}{TSS_a} = 1 - \frac{RSS_b}{TSS_b} = R_b^2$$

4.11. Да, верно.

$$RSS_1 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = y'(I - X(X'X)^{-1}X')y$$

$$RSS_2 = y'(I - Z(Z'Z)^{-1}Z')y = y'(I - XD(D'X'XD)^{-1}D'X')y =$$

так как  $D$  является квадратной и невырожденной, то используя формулу  $(AB)^{-1} = B^{-1}A^{-1}$ , получим:

$$\begin{aligned} RSS_2 &= y'(I - XD(D'X'XD)^{-1}D'X')y = y'(I - XDD^{-1}(X'X)^{-1}D'^{-1}D'X')y = \\ &= y'(I - X(X'X)^{-1}X')y = RSS_1 \end{aligned}$$

4.12.

4.13.

1.  $n = 5$

2.  $k = 3$

3.  $TSS = 10$

4.  $RSS = 2$

5.  $\hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \end{pmatrix} = (X'X)^{-1}X'y = \begin{pmatrix} 2 \\ 2 \\ 1 \end{pmatrix}$

6.  $R^2 = 1 - \frac{RSS}{TSS} = 0.8$ .  $R^2$  высокий, построенная эконометрическая модель «хорошо» описывает данные

7. Основная гипотеза —  $H_0 : \beta_2 = 0$ , альтернативная гипотеза —  $H_a : \beta_2 \neq 0$

8. Проверка гипотезы

(a)  $T = \frac{\hat{\beta}_2 - \beta_2}{\sqrt{\widehat{Var}(\hat{\beta}_2)}} = \frac{\hat{\beta}_2 - \beta_2}{\sqrt{\frac{RSS}{n-k}[(X'X)^{-1}]_{22}}}; n = 5; k = 3$

(b)  $T \sim t(n-k); n = 5; k = 3$

(c)  $T_{obs} = \frac{\hat{\beta}_2 - 0}{\sqrt{\widehat{Var}(\hat{\beta}_2)}} = \frac{\hat{\beta}_2 - 0}{\sqrt{\frac{RSS}{n-k}[(X'X)^{-1}]_{22}}} = \frac{2-0}{\sqrt{\frac{2}{5-3}1.3333}} = 1.7321$

(d) Нижняя граница = -2.920, верхняя граница = 2.920

(e) Поскольку  $T_{obs} = 1.7321$ , что принадлежит промежутку от -2.920 до 2.920, то на основе имеющихся данных нельзя отвергнуть основную гипотезу на уровне значимости 10%

9.  $p\text{-value}(T_{obs}) = \mathbb{P}(|T| > |T_{obs}|) = 2F_T(|T_{obs}|)$ , где  $F_T(|T_{obs}|)$  — функция распределения  $t$ -распределения с  $n-k = 5-3 = 2$  степенями свободы в точке  $|T_{obs}|$ .  $p\text{-value}(T_{obs}) = 2tcdf(-|T_{obs}|, n-k) = 2tcdf(-1.7321, 2) = 0.2253$ . Поскольку  $P$ -значение превосходит уровень значимости 10%, то основная гипотеза —  $H_0 : \beta_2 = 0$  не может быть отвергнута

10. Проверка гипотезы

(a)  $T = \frac{\hat{\beta}_2 - \beta_2}{\sqrt{\widehat{Var}(\hat{\beta}_2)}} = \frac{\hat{\beta}_2 - \beta_2}{\sqrt{\frac{RSS}{n-k}[(X'X)^{-1}]_{22}}}; n = 5; k = 3$

(b)  $T \sim t(n-k); n = 5; k = 3$

(c)  $T_{obs} = \frac{\hat{\beta}_2 - 1}{\sqrt{\widehat{Var}(\hat{\beta}_2)}} = \frac{\hat{\beta}_2 - 1}{\sqrt{\frac{RSS}{n-k}[(X'X)^{-1}]_{22}}} = \frac{2-1}{\sqrt{\frac{2}{5-3}1.3333}} = 0.8660$

(d) Нижняя граница = -2.920, верхняя граница = 2.920

(e) Поскольку  $T_{obs} = 0.8660$ , что принадлежит промежутку от -2.920 до 2.920, то на основе имеющихся данных нельзя отвергнуть основную гипотезу на уровне значимости 10%

11. Проверка гипотезы

(a)  $T = \frac{\hat{\beta}_2 - \beta_2}{\sqrt{\widehat{Var}(\hat{\beta}_2)}} = \frac{\hat{\beta}_2 - \beta_2}{\sqrt{\frac{RSS}{n-k}[(X'X)^{-1}]_{22}}}; n = 5; k = 3$

(b)  $T \sim t(n-k); n = 5; k = 3$

(c)  $T_{obs} = \frac{\hat{\beta}_2 - 1}{\sqrt{\widehat{Var}(\hat{\beta}_2)}} = \frac{\hat{\beta}_2 - 1}{\sqrt{\frac{RSS}{n-k}[(X'X)^{-1}]_{22}}} = \frac{2-1}{\sqrt{\frac{2}{5-3}1.3333}} = 0.8660$

(d) Нижняя граница =  $-\infty$ , верхняя граница = 1.8856

(e) Поскольку  $T_{obs} = 0.8660$ , что принадлежит промежутку от  $-\infty$  до 1.8856, то на основе имеющихся данных нельзя отвергнуть основную гипотезу на уровне значимости 10%



## 12. Проверка гипотезы

- (a)  $T = \frac{\hat{\beta}_2 - \beta_2}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2)}} = \frac{\hat{\beta}_2 - \beta_2}{\sqrt{\frac{RSS}{n-k} [(X'X)^{-1}]_{22}}}; n = 5; k = 3$
- (b)  $T \sim t(n - k); n = 5; k = 3$
- (c)  $T_{obs} = \frac{\hat{\beta}_2 - 1}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2)}} = \frac{\hat{\beta}_2 - 1}{\sqrt{\frac{RSS}{n-k} [(X'X)^{-1}]_{22}}} = \frac{2-1}{\sqrt{\frac{2}{5-3} 1.3333}} = 0.8660$
- (d) Нижняя граница =  $-1.8856$ , верхняя граница =  $+\infty$
- (e) Поскольку  $T_{obs} = 0.8660$ , что принадлежит промежутку от  $-1.8856$  до  $+\infty$ , то на основе имеющихся данных нельзя отвергнуть основную гипотезу на уровне значимости 10%

13. Основная гипотеза —  $H_0 : \beta_2 = \beta_3 = 0$ , альтернативная гипотеза —  $H_a : |\beta_2| + |\beta_3| > 0$ 

## 14. Проверка гипотезы

- (a)  $T = \frac{R^2}{1-R^2} \cdot \frac{n-k}{k}; n = 5; k = 3$
- (b)  $T \sim F(n - k); n = 5; k = 3$
- (c)  $T_{obs} = \frac{R^2}{1-R^2} \cdot \frac{n-k}{k} = \frac{0.8}{1-0.8} \cdot \frac{5-3}{2} = 4$
- (d) Нижняя граница = 0, верхняя граница = 19
- (e) Поскольку  $T_{obs} = 4$ , что принадлежит промежутку от 0 до 19, то на основе имеющихся данных нельзя отвергнуть основную гипотезу на уровне значимости 5%. Следовательно, регрессия в целом незначима. Напомним, что  $R^2 = 0.8$ , то есть он высокий. Но при этом регрессия «в целом» незначима. Такой эффект может возникать при малом объеме выборки, например, таком, как в данной задаче

15.  $p - value(T_{obs}) = \mathbb{P}(|T| > |T_{obs}|) = 2F_T(|T_{obs}|)$ , где  $F_T(|T_{obs}|)$  — функция распределения  $F$ -распределения с  $k = 3$  и  $n - k = 5 - 3 = 2$  степенями свободы в точке  $T_{obs}$ .  $p - value(T_{obs}) = 1 - fcdf(-|T_{obs}|, n - k) = 1 - fcdf(4, 2) = 0.2$ . Поскольку  $P$ -значение превосходит уровень значимости 10%, то основная гипотеза —  $H_0 : \beta_2 = \beta_3 = 0$  не может быть отвергнута. Таким образом, регрессия «в целом» незначима

## 16. Проверка гипотезы

- (a)  $T = \frac{\hat{\beta}_2 + \hat{\beta}_3 - (\beta_2 + \beta_3)}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}}$ , где  $\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3) = \widehat{\text{Var}}(\hat{\beta}_2) + \widehat{\text{Var}}(\hat{\beta}_3) + 2\widehat{\text{Cov}}(\hat{\beta}_2; \hat{\beta}_3) = \hat{\sigma}^2[(X'X)^{-1}]_{22} + 2\hat{\sigma}^2[(X'X)^{-1}]_{23} + \hat{\sigma}^2[(X'X)^{-1}]_{33} = \frac{RSS}{n-k}([(X'X)^{-1}]_{22} + 2[(X'X)^{-1}]_{23} + [(X'X)^{-1}]_{33})$
- (b)  $T \sim t(n - k); n = 5; k = 3$
- (c)  $\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3) = \frac{RSS}{n-k}([(X'X)^{-1}]_{22} + 2[(X'X)^{-1}]_{23} + [(X'X)^{-1}]_{33}) = \frac{2}{5-3}(1.3333 + 2(-1.0000) + 2.0000) = 1.3333$ . Тогда  $T_{obs} = \frac{\hat{\beta}_2 + \hat{\beta}_3 - 2}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}} = \frac{2+1-2}{\sqrt{1.3333}} = 0.8660$
- (d) Нижняя граница =  $-4.3027$ , верхняя граница =  $4.3027$
- (e) Поскольку  $T_{obs} = 0.8660$ , что принадлежит промежутку от  $-4.3027$  до  $4.3027$ , то на основе имеющихся данных нельзя отвергнуть основную гипотезу на уровне значимости 5%

## 17. Проверка гипотезы

- (a)  $T = \frac{\hat{\beta}_2 + \hat{\beta}_3 - (\beta_2 + \beta_3)}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}}$ , где  $\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3) = \widehat{\text{Var}}(\hat{\beta}_2) + \widehat{\text{Var}}(\hat{\beta}_3) + 2\widehat{\text{Cov}}(\hat{\beta}_2; \hat{\beta}_3) = \hat{\sigma}^2[(X'X)^{-1}]_{22} + 2\hat{\sigma}^2[(X'X)^{-1}]_{23} + \hat{\sigma}^2[(X'X)^{-1}]_{33} = \frac{RSS}{n-k}([(X'X)^{-1}]_{22} + 2[(X'X)^{-1}]_{23} + [(X'X)^{-1}]_{33})$
- (b)  $T \sim t(n - k); n = 5; k = 3$
- (c)  $\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3) = \frac{RSS}{n-k}([(X'X)^{-1}]_{22} + 2[(X'X)^{-1}]_{23} + [(X'X)^{-1}]_{33}) = \frac{2}{5-3}(1.3333 + 2(-1.0000) + 2.0000) = 1.3333$ . Тогда  $T_{obs} = \frac{\hat{\beta}_2 + \hat{\beta}_3 - 2}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}} = \frac{2+1-2}{\sqrt{1.3333}} = 0.8660$
- (d) Нижняя граница =  $-\infty$ , верхняя граница =  $2.9200$

- (е) Поскольку  $T_{obs} = 0.8660$ , что принадлежит промежутку от  $-\infty$  до  $2.9200$ , то на основе имеющихся данных нельзя отвергнуть основную гипотезу на уровне значимости 5%

#### 18. Проверка гипотезы

- (а)  $T = \frac{\hat{\beta}_2 + \hat{\beta}_3 - (\beta_2 + \beta_3)}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}}$ , где  $\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3) = \widehat{\text{Var}}(\hat{\beta}_2) + \widehat{\text{Var}}(\hat{\beta}_3) + 2\widehat{\text{Cov}}(\hat{\beta}_2; \hat{\beta}_3) = \hat{\sigma}^2[(X'X)^{-1}]_{22} + 2\hat{\sigma}^2[(X'X)^{-1}]_{23} + \hat{\sigma}^2[(X'X)^{-1}]_{33} = \frac{RSS}{n-k}([(X'X)^{-1}]_{22} + 2[(X'X)^{-1}]_{23} + [(X'X)^{-1}]_{33})$
- (б)  $T \sim t(n-k); n=5; k=3$
- (с)  $\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3) = \frac{RSS}{n-k}([(X'X)^{-1}]_{22} + 2[(X'X)^{-1}]_{23} + [(X'X)^{-1}]_{33}) = \frac{2}{5-3}(1.3333 + 2(-1.0000) + 2.0000) = 1.3333$ . Тогда  $T_{obs} = \frac{\hat{\beta}_2 + \hat{\beta}_3 - 2}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}} = \frac{2+1-2}{\sqrt{1.3333}} = 0.8660$
- (д) Нижняя граница  $= -2.9200$ , верхняя граница  $= +\infty$
- (е) Поскольку  $T_{obs} = 0.8660$ , что принадлежит промежутку от  $-2.9200$  до  $+\infty$ , то на основе имеющихся данных нельзя отвергнуть основную гипотезу на уровне значимости 5%

4.14.

4.15.

$$4.16. \text{Var}(\hat{\beta}) = \sigma^2(X'X)^{-1}$$

$$4.17. (n-1)\sigma^2, (n-k)\sigma^2$$

$$4.18. TSS = y'(I - \pi)y, RSS = y'(I - P)y, ESS = y'(P - \pi)y$$

$$4.19. \mathbb{E}(TSS) = (n-1)\sigma^2 + \beta'X'(I - \pi)X\beta$$

$$4.20. (n-1)\sigma^2, (n-k)\sigma^2, (k-1)\sigma^2$$

4.21.

4.22.  $\mathbb{E}(\varepsilon) = 0$ ,  $\mathbb{E}(\hat{\varepsilon}) = 0$ ,  $\sum \varepsilon_i$  может оказаться равной нулю только случайно, в нормальной модели это происходит с вероятностью 0,  $\sum \hat{\varepsilon}_i = 0$  в модели со свободным членом

$$4.23. \sum y_i^2 = \sum \hat{y}_i^2 + \sum \varepsilon_i^2, TSS = ESS + RSS,$$

4.24.

4.25. Спроецируем единичный столбец на «плоскость», обозначим его  $1'$ . Делаем проекцию  $y$  на «плоскость» и на  $1'$ . Далее аналогично.

4.26. Проекция  $y$  на  $\hat{y}$  это  $\hat{y}$ , поэтому оценки коэффициентов будут 0 и 1. Оценка дисперсии  $\frac{RSS}{(n-2)ESS}$ . Нарушены предпосылки теоремы Гаусса-Маркова, например, ошибки новой модели в сумме дают 0, значит коррелированы.

4.27. Либо в регрессию включена константа, либо единичный столбец (тут была опечатка, столбей) можно получить как линейную комбинацию регрессоров, например, включены дамми-переменные для каждого возможного значения качественной переменной.

4.28. Сами оценки коэффициентов никак детерминистически не связаны, но при большом размере подвыборок примерно равны. А ковариационные матрицы связаны соотношением  $\text{Var}(\hat{\beta}_a)^{-1} + \text{Var}(\hat{\beta}_b)^{-1} = \text{Var}(\hat{\beta}_{tot})^{-1}$

4.29.

4.30.

4.31.

4.32. Подсказка: запишите матрицу  $X$  как блочную и, пользуясь матричным выражением для  $\hat{\beta}$  и формулой Фробениуса, найдите  $\hat{\beta}_2$ .

1. Да, верно.  $X = (X_1 X_2)$  — блочная матрица. Аналогично,  $\hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix}$  — блочная матрица (хотя на самом деле вектор).

$$\begin{aligned} \hat{\beta} &= (X'X)^{-1}X'y = ((X_1X_2)'(X_1X_2))^{-1}(X_1X_2)'y = \left( \begin{pmatrix} X_1' \\ X_2' \end{pmatrix} (X_1X_2) \right)^{-1} \begin{pmatrix} X_1' \\ X_2' \end{pmatrix} y = \\ &= \begin{pmatrix} X_1'X_1 & X_1'X_2 \\ X_2'X_1 & X_2'X_2 \end{pmatrix}^{-1} \begin{pmatrix} X_1' \\ X_2' \end{pmatrix} y \end{aligned}$$

Запишем и докажем формулу Фробениуса для обращения блочных матриц.

Формула Фробениуса:

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} = \begin{pmatrix} A^{-1} + A^{-1}BH^{-1}CA^{-1} & -A^{-1}BH^{-1} \\ -H^{-1}CA^{-1} & H^{-1} \end{pmatrix}$$

где  $H = D - CA^{-1}B$ .

Докажем формулу, обращая матрицу методом Гаусса. Умножим слева на  $\begin{pmatrix} A^{-1} & 0 \\ 0 & I \end{pmatrix}$

$$\left( \begin{array}{cc|cc} A & B & I & 0 \\ C & D & 0 & I \end{array} \right) = \left( \begin{array}{cc|cc} I & A^{-1}B & A^{-1} & 0 \\ C & D & 0 & I \end{array} \right) =$$

вычтем из второй строки первую, умноженную на  $C$

$$= \left( \begin{array}{cc|cc} I & A^{-1}B & A^{-1} & 0 \\ 0 & D - CA^{-1}B & -CA^{-1} & I \end{array} \right) =$$

умножим слева на  $\begin{pmatrix} I & 0 \\ 0 & (D - CA^{-1}B)^{-1} \end{pmatrix}$

$$= \left( \begin{array}{cc|cc} I & A^{-1}B & A^{-1} & 0 \\ 0 & I & -(D - CA^{-1}B)^{-1}CA^{-1} & (D - CA^{-1}B)^{-1} \end{array} \right) =$$

вычтем из первой строки вторую, умноженную на  $A^{-1}B$ .

$$= \left( \begin{array}{cc|cc} I & 0 & A^{-1} + A^{-1}B(D - CA^{-1}B)^{-1}CA^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ 0 & I & -(D - CA^{-1}B)^{-1}CA^{-1} & (D - CA^{-1}B)^{-1} \end{array} \right)$$

Значит,

$$\begin{aligned} \begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} &= \begin{pmatrix} A^{-1} + A^{-1}B(D - CA^{-1}B)^{-1}CA^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ -(D - CA^{-1}B)^{-1}CA^{-1} & (D - CA^{-1}B)^{-1} \end{pmatrix} = \\ &= \begin{pmatrix} A^{-1} + A^{-1}BH^{-1}CA^{-1} & -A^{-1}BH^{-1} \\ -H^{-1}CA^{-1} & H^{-1} \end{pmatrix} \end{aligned}$$

По формуле Фробениуса получим, что

$$\begin{pmatrix} X'_1X_1 & X'_1X_2 \\ X'_2X_1 & X'_2X_2 \end{pmatrix}^{-1} = \begin{pmatrix} (X'_1X_1)^{-1} + (X'_1X_1)^{-1}X'_1X_2H^{-1}X'_2X_1(X'_1X_1)^{-1} & -(X'_1X_1)^{-1}X'_1X_2H^{-1} \\ -H^{-1}X'_2X_1(X'_1X_1)^{-1} & H^{-1} \end{pmatrix},$$

где  $H = X'_2X_2 - X'_2X_1(X'_1X_1)^{-1}X'_1X_2$ . Верхняя строка в данном пункте не важна, и сейчас её опустим. Заметим, что

$$H = X'_2X_2 - X'_2X_1(X'_1X_1)^{-1}X'_1X_2 = X'_2(I - X_1(X'_1X_1)^{-1}X'_1)X_2 = X'_2M_1X_2$$

Итак,

$$\begin{aligned}
 \hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} &= \begin{pmatrix} X_1' X_1 & X_1' X_2 \\ X_2' X_1 & X_2' X_2 \end{pmatrix}^{-1} \begin{pmatrix} X_1' \\ X_2' \end{pmatrix} y = \\
 &= \begin{pmatrix} ? & ? \\ -H^{-1} X_2' X_1 (X_1' X_1)^{-1} & H^{-1} \end{pmatrix} \begin{pmatrix} X_1' \\ X_2' \end{pmatrix} y = \\
 &= \begin{pmatrix} ? \\ -H^{-1} X_2' X_1 (X_1' X_1)^{-1} X_1' + H^{-1} X_2' \end{pmatrix} y = \\
 &= \begin{pmatrix} ? \\ H^{-1} X_2' (I - X_1 (X_1' X_1)^{-1} X_1') \end{pmatrix} y = \\
 &= \begin{pmatrix} ? \\ H^{-1} X_2' M_1 y \end{pmatrix} = \begin{pmatrix} ? \\ (X_2' M_1 X_2)^{-1} X_2' M_1 y \end{pmatrix}
 \end{aligned}$$

$$\hat{\beta}_2 = (X_2' M_1 X_2)^{-1} X_2' M_1 y$$

Заметим свойства матрицы-проектора  $M_1$ .

$$M_1' = (I - X_1 (X_1' X_1)^{-1} X_1')' = I - X_1 (X_1' X_1)^{-1} X_1' = M_1$$

$$\begin{aligned}
 (M_1)^2 &= (I - X_1 (X_1' X_1)^{-1} X_1')^2 = I - 2X_1 (X_1' X_1)^{-1} X_1' + X_1 (X_1' X_1)^{-1} X_1' \cdot X_1 (X_1' X_1)^{-1} X_1' = \\
 &= I - X_1 (X_1' X_1)^{-1} X_1' = M_1
 \end{aligned}$$

Значит,

$$\begin{aligned}
 \hat{\beta}_2 &= (X_2' M_1 X_2)^{-1} X_2' M_1 y = (X_2' M_1 M_1 X_2)^{-1} X_2' M_1 M_1 y = (X_2' M_1' M_1 X_2)^{-1} X_2' M_1' M_1 y = \\
 &= ((M_1 X_2)' M_1 X_2)^{-1} (M_1 X_2)' M_1 y
 \end{aligned}$$

но ведь и

$$\hat{\gamma}_2 = ((M_1 X_2)' M_1 X_2)^{-1} (M_1 X_2)' M_1 y$$

Значит,  $\hat{\beta}_2 = \hat{\gamma}_2 = ((M_1 X_2)' M_1 X_2)^{-1} (M_1 X_2)' M_1 y$ , что и требовалось доказать.

2. Да, верно.

$$\hat{y} = X_1 \hat{\beta}_1 + X_2 \hat{\beta}_2$$

$$M_1 \hat{\varepsilon} = M_1 y - M_1 \hat{y} = M_1 y - M_1 (X_1 \hat{\beta}_1 + X_2 \hat{\beta}_2) = M_1 y - M_1 X_2 \hat{\beta}_2 - M_1 X_1 \hat{\beta}_1$$

$$M_1 X_1 = (I - X_1 (X_1' X_1)^{-1} X_1') X_1 = X_1 - X_1 (X_1' X_1)^{-1} X_1' X_1 = 0$$

$$M_1 \hat{\varepsilon} = M_1 y - M_1 X_2 \hat{\beta}_2 = M_1 y - M_1 X_2 \hat{\gamma}_2 = \hat{u}$$

$$M_1 \hat{\varepsilon} = M_1 (y - \hat{y}) = M_1 (I - X(X'X)^{-1}X')y = (I - X(X'X)^{-1}X')y$$

так как  $M_1$  ортогональное дополнение к  $X_1$ , а  $(I - X(X'X)^{-1}X')y$  уже лежит в ортогональном дополнении к  $X_1$ , так как  $I - X(X'X)^{-1}X'$  ортогональное дополнение к к прямой сумме пространств  $X_1$  и  $X_2 - X_1 \oplus X_2$ .

4.33.

4.34. Докажем несмещенность МНК-оценок.

$$\begin{aligned}
 \mathbb{E} \hat{\beta} &= \mathbb{E} ((X^T X)^{-1} X^T y) = (X^T X)^{-1} X^T \mathbb{E}(y) = \\
 &= (X^T X)^{-1} X^T \mathbb{E}(X\beta + \varepsilon) = (X^T X)^{-1} X^T X\beta = \beta
 \end{aligned}$$

Обозначим  $\varphi(X, y) = (X^T X)^{-1} X^T y$ . Тогда  $\hat{\beta} = \varphi(X, y)$ . Покажем, что функция  $\varphi$  линейна по переменной  $y$ .

$$1. \varphi(X, \lambda \cdot y) = (X^T X)^{-1} X^T (\lambda \cdot y) = \lambda (X^T X)^{-1} X^T y = \lambda \cdot \varphi(X, y)$$

$$2. \varphi(X, y + z) = (X^T X)^{-1} X^T (y + z) = (X^T X)^{-1} X^T y + (X^T X)^{-1} X^T z = \varphi(X, y) + \varphi(X, z)$$

Что и требовалось доказать.

4.35. Нет, так как для функции  $\varphi(X, y) = (X^T X)^{-1} X^T y$  не выполнено, например, свойство однородности по переменной  $X$ . Действительно,

$$\varphi(X, \lambda \cdot y) = ((\lambda \cdot X)^T (\lambda \cdot X))^{-1} (\lambda \cdot X)^T y = \frac{1}{\lambda} \cdot (X^T X)^{-1} X^T y = \frac{1}{\lambda} \varphi(X, y)$$

4.36.  $\tilde{\beta} = (X^T C X)^{-1} X^T C y$ , где

$$C = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ 0 & 2 & 0 & \cdots & 0 \\ 0 & 0 & 3 & \ddots & \vdots \\ \vdots & \vdots & \ddots & \ddots & 0 \\ 0 & 0 & \cdots & 0 & n \end{bmatrix}$$

4.37.  $Pi = i \Leftrightarrow P\pi = \pi$  поскольку, если матрицу  $\pi$  записать по столбцам  $\pi = \frac{1}{n} \begin{bmatrix} i & i & \cdots & i \end{bmatrix}$ , то можно записать следующую цепочку равенств  $P\pi = P \frac{1}{n} \begin{bmatrix} i & i & \cdots & i \end{bmatrix} = \frac{1}{n} \begin{bmatrix} Pi & Pi & \cdots & Pi \end{bmatrix} = \frac{1}{n} \begin{bmatrix} i & i & \cdots & i \end{bmatrix} \Leftrightarrow Pi = i$ .

Свойство  $P^2 = P$  имеет место независимо от выполнимости условия  $Pi = i$ . Действительно,  $P^2 = X(X^T X)^{-1} X^T X(X^T X)^{-1} X^T = X(X^T X)^{-1} X^T = P$ .

Рассмотрите пример  $y = \begin{bmatrix} 1 & -1 & 0 \end{bmatrix}^T$ ,  $x = \begin{bmatrix} 1 & 0 & -1 \end{bmatrix}^T$ . Постройте регрессию  $y = \beta x + \varepsilon$  без свободного члена. Убедитесь, что  $\sum_{i=1}^n \hat{\varepsilon}_i = 0$  и  $\bar{Y} = \bar{\hat{Y}} = 0$ , но  $Pi \neq i$ .

Ответ:  $P\pi = \pi$

4.38. (1), (2)  $\Leftrightarrow$  (3), (5)

4.39.

$$\mathbb{E}(\varepsilon^T \pi \varepsilon) = \mathbb{E}(\text{tr}[\varepsilon^T \pi \varepsilon]) = \mathbb{E}(\text{tr}[\pi \varepsilon \varepsilon^T]) = \text{tr}[\pi \mathbb{E}(\varepsilon \varepsilon^T)] =$$

$$\begin{aligned} \text{tr}[\pi \text{Var}(\varepsilon)] &= \text{tr} \left[ \frac{1}{n} \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ \cdots & \cdots & \cdots & \cdots \\ 1 & 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots \\ 0 & \cdots & 0 & \sigma_n^2 \end{bmatrix} \right] = \\ &= \frac{1}{n} \text{tr} \begin{bmatrix} \sigma_1^2 & \sigma_2^2 & \cdots & \sigma_n^2 \\ \sigma_1^2 & \sigma_2^2 & \cdots & \sigma_n^2 \\ \cdots & \cdots & \cdots & \cdots \\ \sigma_1^2 & \sigma_2^2 & \cdots & \sigma_n^2 \end{bmatrix} = \frac{1}{n} \sum_{i=1}^n \sigma_i^2 \quad (1.27) \end{aligned}$$

4.40.

1.

$$RSS = \hat{\varepsilon}^T \hat{\varepsilon} y^T (I - P) y = y^T y - y^T P y = y^T y - y^T X (X^T X)^{-1} X^T y; \quad (1.28)$$

При этом  $y^T y = 3924$ , а

$$y^T X (X^T X)^{-1} X^T y = \begin{bmatrix} 460 & 810 & 615 & 712 \end{bmatrix} \begin{bmatrix} 0.038 & -0.063 & -0.063 & 0.100 \\ -0.063 & 1.129 & 1.107 & -2.192 \\ -0.063 & 1.107 & 1.110 & -2.170 \\ 0.100 & -2.192 & -2.170 & 4.292 \end{bmatrix} \cdot \begin{bmatrix} 460 \\ 810 \\ 615 \\ 712 \end{bmatrix} = 3051.2 \quad (1.29)$$

Итого,  $RSS = 3924 - 3051.2 = 872.8$

$$\hat{\sigma}_\varepsilon^2 = \frac{RSS}{n-k} = \frac{872.8}{100-4} = 9.0917$$

$$\widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}_\varepsilon^2 (X^T X)^{-1} \Rightarrow \widehat{\text{Cov}}(\hat{\beta}_1, \hat{\beta}_2) = -0.56939, \widehat{\text{Var}}(\hat{\beta}_1) = 0.34251, \widehat{\text{Var}}(\hat{\beta}_2) = 10.269$$

$$\widehat{\text{Corr}}(\hat{\beta}_1, \hat{\beta}_2) = \frac{\widehat{\text{Cov}}(\hat{\beta}_1, \hat{\beta}_2)}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_1)} \sqrt{\widehat{\text{Var}}(\hat{\beta}_2)}} = -0.30361$$

2. (указание)  $\widehat{\text{Corr}}(x_2, x_3) = \frac{\sum (x_{i2} - \bar{x}_2)(x_{i3} - \bar{x}_3)}{\sqrt{\sum (x_{i2} - \bar{x}_2)^2} \sqrt{\sum (x_{i3} - \bar{x}_3)^2}}$ . Все необходимые величины можно извлечь из матрицы  $X^T X$  — это величины  $\sum x_{i2}$  и  $\sum x_{i3}$ , а остальное — из матрицы  $X^T(I - \pi)X = X^T X - X^T \pi X = X^T X - (\pi X)^T \pi X$ . При этом имейте в виду, что  $\pi X = \begin{bmatrix} 1 & \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \\ \dots & \dots & \dots & \dots \\ 1 & \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \end{bmatrix}$  и  $\bar{x}_1 = 1.23$ ,  $\bar{x}_2 = 0.96$ ,  $\bar{x}_3 = 1.09$

$$3. \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \\ \hat{\beta}_4 \\ \hat{\beta}_5 \end{bmatrix} = \begin{bmatrix} 0.03767 & -0.06263 & -0.06247 & 0.1003 \\ -0.06263 & 1.129 & 1.107 & -2.192 \\ -0.06247 & 1.107 & 1.110 & -2.170 \\ 0.1003 & -2.192 & -2.170 & 4.292 \end{bmatrix} \begin{bmatrix} 460 \\ 810 \\ 615 \\ 712 \end{bmatrix} = \begin{bmatrix} -0.40221 \\ 6.1234 \\ 5.9097 \\ -7.5256 \end{bmatrix}$$

$$t = \frac{\hat{\beta}_2}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2)}} \sim t_{100-4}$$

$$t = \frac{\hat{\beta}_2}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2)}} = \frac{6.1234}{\sqrt{10.269}} = 1.9109 \Rightarrow \hat{\beta}_2 \text{ — не значим.}$$

4.41.

1.  $\widehat{\text{Cov}} \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \end{bmatrix} = \hat{\sigma}_\varepsilon^2 (X^T X)^{-1}$  — несмещённая оценка для ковариационной матрицы

$$\text{МНК-коэффициентов. Действительно, } \mathbb{E} \widehat{\text{Cov}} \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \end{bmatrix} = \mathbb{E} \hat{\sigma}_\varepsilon^2 (X^T X)^{-1} = \sigma_\varepsilon^2 (X^T X)^{-1} = \text{Cov} \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \end{bmatrix}.$$

Поэтому искомая оценка  $\widehat{\text{Cov}}(\hat{\beta}_2, \hat{\beta}_3) = \hat{\sigma}_\varepsilon^2 [(X^T X)^{-1}]_{23}$ , где  $[(X^T X)^{-1}]_{23}$  — элемент матрицы  $(X^T X)^{-1}$ , расположенный во второй строке, 3-м столбце.

$$\text{Заметим, что } \hat{\sigma}_{\hat{\beta}_2}^2 = \hat{\sigma}_\varepsilon^2 [(X^T X)^{-1}]_{22} \Rightarrow 0.7^2 = \hat{\sigma}_\varepsilon^2 \cdot (3030) \Rightarrow \hat{\sigma}_\varepsilon^2 = 0.00016172$$

$$\text{Значит, } \widehat{\text{Cov}}(\hat{\beta}_2, \hat{\beta}_3) = 0.00016172 \cdot (-589) = -0.095253.$$

2.  $t = \frac{\hat{\beta}_2 + \hat{\beta}_3 - \beta_2 - \beta_3}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}} \sim t_{n-k}$

Требуется проверить  $H_0 : \beta_2 + \beta_3 = 1$ .

$$\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3) = \widehat{\text{Var}}(\hat{\beta}_2) + \widehat{\text{Var}}(\hat{\beta}_3) + 2\widehat{\text{Cov}}(\hat{\beta}_2, \hat{\beta}_3) = 0.7^2 + 0.138^2 + 2 \cdot 0.095253 = 0.319044$$

$$t = \frac{\hat{\beta}_2 + \hat{\beta}_3 - \beta_2 - \beta_3}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}} = \frac{0.76 + 0.19 - 1}{\sqrt{0.319044}} = -0.088520674$$

Значит, гипотеза не отвергается на любом «разумном» уровне значимости.

3. Мы знаем, что  $\frac{\hat{\beta}_2 + \hat{\beta}_3 - \beta_2 - \beta_3}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}} \sim t_{n-k} = t_{15-3}$ , поэтому построить доверительный интервал для  $\beta_2 + \beta_3$  не составляет труда.  $\mathbb{P} \left( \left| \frac{\hat{\beta}_2 + \hat{\beta}_3 - \beta_2 - \beta_3}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}} \right| < t^* \right) = 0.95$

Обозначим  $se = \sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}$ , тогда:

$$\begin{aligned} \mathbb{P} \left( \left| \frac{\hat{\beta}_2 + \hat{\beta}_3 - \beta_2 - \beta_3}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2 + \hat{\beta}_3)}} \right| < t^* \right) &= \\ \mathbb{P} \left( -t^* se < \hat{\beta}_2 + \hat{\beta}_3 - \beta_2 - \beta_3 < t^* se \right) &= \\ \mathbb{P} \left( -t^* se - (\hat{\beta}_2 + \hat{\beta}_3) < -\beta_2 - \beta_3 < -(\hat{\beta}_2 + \hat{\beta}_3) + t^* se \right) &= \\ \mathbb{P} \left( (\hat{\beta}_2 + \hat{\beta}_3) + t^* se > \beta_2 + \beta_3 > (\hat{\beta}_2 + \hat{\beta}_3) - t^* se \right) & \quad (1.30) \end{aligned}$$

Отсюда получаем доверительный интервал

$$\beta_2 + \beta_3 \in [ (0.76 + 0.19) - 2.16 \cdot 0.319; (0.76 + 0.19) + 2.16 \cdot 0.319 ] \quad (1.31)$$

Или  $0.26 < \beta_2 + \beta_3 < 1.639$

4.42.

Метод наименьших квадратов:

$$\begin{aligned} \hat{\epsilon}'\hat{\epsilon} &\rightarrow \min_{\hat{\beta}} \\ (y - \hat{y})'(y - \hat{y}) &\rightarrow \min_{\hat{\beta}} \\ (y - X\hat{\beta})'(y - X\hat{\beta}) &\rightarrow \min_{\hat{\beta}} \\ y'y - \hat{\beta}'X'y - y'X\hat{\beta} + \hat{\beta}'X'X\hat{\beta} &\rightarrow \min_{\hat{\beta}} \end{aligned}$$

Воспользуемся тем, что :  $\frac{\partial x'A}{\partial x'} = A'$ ,  $\frac{\partial Ax}{\partial x'} = A$ ,  $\frac{\partial x'Ax}{\partial x'} = x'(A' + A)$  Условие первого порядка:

$$\begin{aligned} -2(X'y)' + (X'X + (X'X)')\hat{\beta}' &= 0 \\ -2X'y + 2\hat{\beta}'X'X &= 0 \end{aligned}$$

и

$$\hat{\beta} = (X'X)^{-1}X'y$$

$$\begin{aligned} \text{Var}(\hat{\beta}) &= \text{Var}((X'X)^{-1}X'y) = (X'X)^{-1}X' \text{Var}(y)((X'X)^{-1}X')' = \\ &= (X'X)^{-1}X' \text{Var}(X\beta + \epsilon)X(X'X)^{-1} \end{aligned}$$

Так как  $\beta$  является константой, то  $\text{Var}(X\beta) = 0$ . Тогда

$$\begin{aligned}\text{Var}(\hat{\beta}) &= (X'X)^{-1}X' \text{Var}(X\beta + \epsilon)X(X'X)^{-1} = \\ &= (X'X)^{-1}X' \text{Var}(\epsilon)X(X'X)^{-1} = (X'X)^{-1}X'\sigma^2X(X'X)^{-1} = \\ &= \sigma^2(X'X)^{-1}X'X(X'X)^{-1} = \sigma^2(X'X)^{-1}\end{aligned}$$

4.43. Находим  $X'X$ , её элементы и есть то, что нужно.

4.44.

$$\widehat{\text{Var}}(\hat{\beta}_1 + \hat{\beta}_2 - \hat{\beta}_3) = \text{Var}(\hat{\beta}_1) + \text{Var}(\hat{\beta}_2) + \text{Var}(\hat{\beta}_3) + 2\text{Cov}(\hat{\beta}_1, \hat{\beta}_2) - 2\text{Cov}(\hat{\beta}_1, \hat{\beta}_3) - 2\text{Cov}(\hat{\beta}_2, \hat{\beta}_3)$$

$$\widehat{\text{Var}}(\hat{\beta}_1 + \hat{\beta}_2 - \hat{\beta}_3) = 1/3 + 4/3 + 2 - 2/3 + 2 = 5$$

4.45. Из того, что  $\widehat{\text{Var}}(\hat{\beta}) = \sigma^2 \cdot (X'X)^{-1}$  видно, что  $\sigma^2 = \frac{1}{3}$ .

$$RSS = \sigma^2 \cdot (n - k) = 1/3 \cdot 2 = 2/3$$

$$R^2 = 49 \frac{1}{3} / 50 = 148/150$$

$F = \frac{R^2/(k-1)}{(1-R^2)/(n-k)} = \frac{148/2}{2/2} = 74$   $F_{0.05,2,2}^{crit} = 19 < 74$  гипотеза отвергается, регрессия значима.

5.1.

5.2.

5.3.

$$5.4. \hat{\theta} = 1/\bar{Y}, \hat{\beta} = \bar{X}/\bar{Y}, \hat{a} = 1/(1 + \bar{X})$$

5.5. В данном примере мы имеем

$\theta = [\mu \quad \nu]'$  — вектор неизвестных параметров

$\Theta = \mathbb{R} \times (0; +\infty)$  — множество допустимых значений вектора неизвестных параметров

Функция правдоподобия имеет вид:

$$\begin{aligned}L(\theta) &= \prod_{i=1}^n f_{X_i}(x_i, \theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\nu}} \cdot \exp \left\{ -\frac{(x_i - \mu)^2}{2\nu} \right\} = \\ &= (2\pi)^{-n/2} \cdot \nu^{-n/2} \cdot \exp \left\{ -\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\nu} \right\} \quad (1.32)\end{aligned}$$

Логарифмическая функция правдоподобия:

$$l(\theta) := \ln L(\theta) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \nu - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\nu}$$

$$\Theta_{UR} = \Theta$$

$$\Theta_R = \{(0, 1)\}$$

Из системы уравнений

$$\begin{cases} \frac{\partial l}{\partial \mu} = \frac{\sum_{i=1}^n (x_i - \mu)}{\nu} = 0 \\ \frac{\partial l}{\partial \nu} = -\frac{n}{2\nu} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\nu^2} = 0 \end{cases}$$

находим

$$\hat{\theta}_{UR} = (\hat{\mu}_{UR}, \hat{\nu}_{UR}), \text{ где } \hat{\mu}_{UR} = \bar{x} = -1.5290, \hat{\nu}_{UR} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = 1.0603$$

$$\hat{\theta}_R = (\hat{\mu}_R, \hat{\nu}_R) = (0, 1)$$

По имеющимся данным находим

$$l(\hat{\theta}_R) = -\frac{10}{2} \ln(2\pi) - \frac{10}{2} \ln 1 - \frac{\sum_{i=1}^n (x_i - 0)^2}{2 \cdot 1} = -26.1804$$

$$l = -\frac{10}{2} \ln(2\pi) - \frac{10}{2} \ln(1.0603) - \frac{\sum_{i=1}^n (x_i + 1.5290)^2}{2 \cdot 1.0603} = -14.4824$$

$$LR_{\text{набл}} = -2(l(\hat{\theta}_R) - l) = -2 \cdot (-26.1804 + 14.4824) = 23.3959$$



Критическое значение  $\chi^2$  распределения с двумя степенями свободы, отвечающее уровню значимости 5%, равно 5.9915. Следовательно, тест отношения правдоподобия говорит о том, что гипотеза  $H_0$  должна быть отвергнута.

Для выполнения тестов Вальда и множителей Лагранжа нам понадобится информационная матрица Фишера

$$\begin{aligned} \frac{\partial^2 l}{\partial \mu^2} &= -\frac{n}{v}, \quad \frac{\partial^2 l}{\partial \nu \partial \mu} = -\frac{\sum_{i=1}^n (x_i - \mu)}{\nu^2}, \quad \frac{\partial^2 l}{\partial \nu^2} = \frac{n}{2\nu^2} - \frac{\sum_{i=1}^n (x_i - \mu)^2}{\nu^3} \\ \mathbb{E} \frac{\partial^2 l}{\partial \nu \partial \mu} &= -\frac{\sum_{i=1}^n \mathbb{E}(x_i - \mu)}{\nu^2} = 0, \quad \mathbb{E} \frac{\partial^2 l}{\partial \nu^2} = \frac{n}{2\nu^2} - \frac{\sum_{i=1}^n \mathbb{E}(x_i - \mu)^2}{\nu^3} = \frac{n}{2\nu^2} - \frac{n\nu}{n\nu^3} = -\frac{n}{2\nu^2} \\ I(\theta) &= -\mathbb{E} \begin{bmatrix} \frac{\partial^2 l}{\partial \mu^2} & \frac{\partial^2 l}{\partial \nu \partial \mu} \\ \frac{\partial^2 l}{\partial \nu \partial \mu} & \frac{\partial^2 l}{\partial \nu^2} \end{bmatrix} = \begin{bmatrix} \frac{n}{\nu} & 0 \\ 0 & \frac{n}{2\nu^2} \end{bmatrix} \\ I(\hat{\theta}_{UR}) &= \begin{bmatrix} \frac{n}{\hat{\nu}_{UR}} & 0 \\ 0 & \frac{n}{2 \cdot \hat{\nu}_{UR}^2} \end{bmatrix} = \begin{bmatrix} \frac{10}{1.0603} & 0 \\ 0 & \frac{10}{2 \cdot 1.0603^2} \end{bmatrix} = \begin{bmatrix} 9.4307 & 0 \\ 0 & 4.4469 \end{bmatrix} \\ g(\hat{\theta}_{UR}) &= \begin{bmatrix} \hat{\mu}_{UR} - 0 \\ \hat{\nu}_{UR} - 1 \end{bmatrix} = \begin{bmatrix} -1.5290 - 0 \\ 1.0603 - 1 \end{bmatrix} = \begin{bmatrix} -1.5290 \\ 0.0603 \end{bmatrix} \\ \frac{\partial g}{\partial \theta'} &= \begin{bmatrix} \frac{\partial g_1}{\partial \mu} & \frac{\partial g_1}{\partial \nu} \\ \frac{\partial g_2}{\partial \mu} & \frac{\partial g_2}{\partial \nu} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \frac{\partial g'}{\partial \theta} = \begin{bmatrix} \frac{\partial g_1}{\partial \mu} & \frac{\partial g_2}{\partial \mu} \\ \frac{\partial g_1}{\partial \nu} & \frac{\partial g_2}{\partial \nu} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \\ W_{\text{набл}} &= g'(\hat{\theta}_{UR}) \cdot \left[ \frac{\partial g}{\partial \theta'}(\hat{\theta}_{UR}) \cdot I^{-1}(\hat{\theta}_{UR}) \cdot \frac{\partial g'}{\partial \theta}(\hat{\theta}_{UR}) \right]^{-1} g(\hat{\theta}_{UR}) = \\ &= \begin{bmatrix} -1.5290 & 0.0603 \end{bmatrix} \cdot \left[ \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 9.4307 & 0 \\ 0 & 4.4469 \end{bmatrix}^{-1} \cdot \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \right]^{-1} \cdot \begin{bmatrix} -1.5290 \\ 0.0603 \end{bmatrix} = 22.0635 \end{aligned}$$

Тест Вальда также говорит о том, что на основании имеющихся наблюдений гипотеза  $H_0$  должна быть отвергнута.

$$\begin{aligned} I(\hat{\theta}_R) &= \begin{bmatrix} \frac{n}{\hat{\nu}_R} & 0 \\ 0 & \frac{n}{2 \cdot \hat{\nu}_R^2} \end{bmatrix} = \begin{bmatrix} \frac{10}{1} & 0 \\ 0 & \frac{10}{2 \cdot 1^2} \end{bmatrix} = \begin{bmatrix} 10 & 0 \\ 0 & 5 \end{bmatrix} \\ \frac{\partial l}{\partial \theta}(\hat{\theta}_R) &= \begin{bmatrix} \frac{\sum_{i=1}^n (x_i - \hat{\mu}_R)}{\hat{\nu}_R} \\ -\frac{n}{2 \cdot \hat{\nu}_R} + \frac{\sum_{i=1}^n (x_i - \hat{\mu}_R)^2}{2 \cdot \hat{\nu}_R^2} \end{bmatrix} = \begin{bmatrix} \frac{\sum_{i=1}^n (x_i - 0)}{1} \\ -\frac{10}{2 \cdot 1} + \frac{\sum_{i=1}^n (x_i - 0)^2}{2 \cdot 1^2} \end{bmatrix} = \begin{bmatrix} -15.29 \\ 11.9910 \end{bmatrix} \\ LM_{\text{набл}} &= \left[ \frac{\partial l}{\partial \theta}(\hat{\theta}_R) \right]' \cdot I^{-1}(\hat{\theta}_R) \cdot \left[ \frac{\partial l}{\partial \theta}(\hat{\theta}_R) \right] = \begin{bmatrix} -15.29 & 11.9910 \end{bmatrix} \cdot \begin{bmatrix} 10 & 0 \\ 0 & 5 \end{bmatrix}^{-1} \cdot \begin{bmatrix} -15.29 \\ 11.9910 \end{bmatrix} = 52.1354 \end{aligned}$$

Тест множителей Лагранжа также указывает на то, что гипотеза  $H_0$  должна быть отвергнута.

5.6. В данной задаче мы имеем:

$\theta = p$  — вектор неизвестных параметров

$\Theta = (0, 1)$  — множество допустимых значений вектора неизвестных параметров

Функция правдоподобия имеет вид:

$$L(\theta) = \prod_{i=1}^n \mathbb{P}_{\theta}(X_i = x_i) = \prod_{i=1}^n p^{x_i} \cdot (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} \cdot (1-p)^{n-\sum_{i=1}^n x_i}$$

Логарифмическая функция правдоподобия:

$$l(\theta) := \ln L(\theta) = \left( \sum_{i=1}^n x_i \right) \cdot \ln p + \left( n - \sum_{i=1}^n x_i \right) \cdot \ln(1-p)$$

$$\Theta_{UR} = \Theta$$

$$\Theta_R = \{0.5\}$$

Решая уравнение правдоподобия

$$\frac{\partial l}{\partial p} = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0$$

получаем

$$\hat{\theta}_{UR} = \hat{p}_{UR}, \text{ где } \hat{p}_{UR} = \bar{x} = 0.42$$

$$\hat{\theta}_R = \hat{p}_R = 0.5$$

По имеющимся данным находим

$$l(\hat{\theta}_R) = 42 \cdot \ln(0.5) + (100 - 42) \cdot \ln(1 - 0.5) = -69.3147$$

$$l(\hat{\theta}_{UR}) = 42 \cdot \ln(0.42) + (100 - 42) \cdot \ln(1 - 0.42) = -68.0292$$

$$LR_{\text{набл}} = -2(l(\hat{\theta}_R) - l) = -2 \cdot (-69.3147 + 68.0292) = 2.5710$$

Критическое значение  $\chi^2$  распределения с одной степенью свободы, отвечающее за 5% уровень значимости, равно 3.8414. Следовательно, тест отношения правдоподобия говорит о том, что на основании имеющихся данных, основная гипотеза  $H_0 : p = 0.5$  не может быть отвергнута.

Для выполнения тестов Вальда и множителей Лагранжа нам понадобится информационная матрица Фишера

$$\frac{\partial^2 l}{\partial p^2} = -\frac{\sum_{i=1}^n x_i}{p^2} - \frac{n - \sum_{i=1}^n x_i}{(1-p)^2}$$

$$I(\theta) = -\mathbb{E} \left[ \frac{\partial^2 l}{\partial p^2} \right] = -\mathbb{E} \left[ -\frac{\sum_{i=1}^n x_i}{p^2} - \frac{n - \sum_{i=1}^n x_i}{(1-p)^2} \right] = -\left( -\frac{np}{p^2} - \frac{n-np}{(1-p)^2} \right) = \frac{n}{p(1-p)}$$

$$I(\hat{\theta}_{UR}) = \frac{n}{\hat{p}_{UR}(1-\hat{p}_{UR})} = \frac{100}{0.42 \times (1-0.42)} = 172.4138$$

$$g(\hat{\theta}_{UR}) = \hat{\theta}_{UR} - 0.5 = 0.42 - 0.5 = -0.08$$

$$\frac{\partial g}{\partial \theta'} = 1', \quad \frac{\partial g'}{\partial \theta} = 1$$

$$W_{\text{набл}} = g'(\hat{\theta}_{UR}) \cdot \left[ \frac{\partial g}{\partial \theta'}(\hat{\theta}_{UR}) \cdot I^{-1}(\hat{\theta}_{UR}) \cdot \frac{\partial g'}{\partial \theta}(\hat{\theta}_{UR}) \right]^{-1} g(\hat{\theta}_{UR}) = [-0.08]' \cdot [1' \cdot 172.4138^{-1} \cdot 1]^{-1} \cdot [-0.08] = 2.6272$$

Тест Вальда также говорит о том, что гипотеза  $H_0$  не отвергается.

$$I(\hat{\theta}_R) = \frac{n}{\hat{p}_R(1-\hat{p}_R)} = \frac{100}{0.5 \times (1-0.5)} = 400$$

$$\frac{\partial l}{\partial \theta}(\hat{\theta}_R) = \frac{\sum_{i=1}^n x_i}{\hat{p}_R} - \frac{n - \sum_{i=1}^n x_i}{1-\hat{p}_R} = \frac{42}{0.5} - \frac{100-42}{1-0.5} = -32$$

$$LM_{\text{набл}} = \left[ \frac{\partial l}{\partial \theta}(\hat{\theta}_R) \right]' \cdot I^{-1}(\hat{\theta}_R) \cdot \left[ \frac{\partial l}{\partial \theta}(\hat{\theta}_R) \right] = [-32]' \cdot [400]^{-1} \cdot [-32] = 2.56$$

Согласно тесту множителей Лагранжа, основная гипотеза  $H_0$  не может быть отвергнута.

5.7. В данной задаче мы имеем

$\theta = \lambda$  — вектор неизвестных параметров

$\Theta = (0, +\infty)$  — множество допустимых значений вектора неизвестных параметров

Функция правдоподобия имеет вид:

$$L(\theta) = \prod_{i=1}^n \mathbb{P}_{\theta}(X_i = x_i) = \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{\lambda^{\sum_{i=1}^n x_i}}{x_1! \dots x_n!} e^{-\lambda n}$$

Логарифмическая функция правдоподобия:

$$l(\theta) := \ln L(\theta) = \left( \sum_{i=1}^n x_i \right) \cdot \ln \lambda - \sum_{i=1}^n \ln(x_i!) - \lambda n$$

$$\Theta_{UR} = \Theta$$

$$\Theta_R = \{2\}$$

Решая уравнение правдоподобия

$$\frac{\partial l}{\partial p} = \frac{\sum_{i=1}^n x_i}{\lambda} - n = 0$$

получаем

$$\hat{\theta}_{UR} = \hat{\lambda}_{UR}, \text{ где } \hat{\lambda}_{UR} = \bar{x} = 1.7$$

$$\hat{\theta}_R = \hat{p}_R = 2$$

По имеющимся данным находим

$$l(\hat{\theta}_R) = (80 \cdot 1.7) \cdot \ln(2) - \sum_{i=1}^n \ln(x_i!) - 2 \cdot 80 = -65.7319$$

$$l(\hat{\theta}_{UR}) = (80 \cdot 1.7) \cdot \ln(1.7) - \sum_{i=1}^n \ln(x_i!) - 1.7 \cdot 80 = -63.8345$$

$$LR_{\text{набл}} = -2(l(\hat{\theta}_R) - l) = -2 \cdot (-65.7319 + 63.8345) = 3.7948$$

Критическое значение  $\chi^2$  распределения с одной степенью свободы, отвечающее за 5% уровень значимости, равно 3.8414. Следовательно, тест отношения правдоподобия говорит о том, что на основании имеющихся данных, основная гипотеза  $H_0 : \lambda = 2$  не может быть отвергнута.

Для выполнения тестов Вальда и множителей Лагранжа нам понадобится информационная матрица Фишера

$$\frac{\partial^2 l}{\partial p^2} = -\frac{\sum_{i=1}^n x_i}{\lambda^2}$$

$$I(\theta) = -\mathbb{E} \left[ \frac{\partial^2 l}{\partial p^2} \right] = -\mathbb{E} \left[ -\frac{\sum_{i=1}^n x_i}{\lambda^2} \right] = -\left(-\frac{n\lambda}{\lambda^2}\right) = \frac{n}{\lambda}$$

$$I(\hat{\theta}_{UR}) = \frac{n}{\hat{\lambda}_{UR}} = \frac{80}{1.7} = 47.0588$$

$$g(\hat{\theta}_{UR}) = \hat{\theta}_{UR} - 2 = 1.7 - 2 = -0.3$$

$$\frac{\partial g}{\partial \theta'} = 1', \quad \frac{\partial g'}{\partial \theta} = 1$$

$$W_{\text{набл}} = g'(\hat{\theta}_{UR}) \cdot \left[ \frac{\partial g}{\partial \theta'}(\hat{\theta}_{UR}) \cdot I^{-1}(\hat{\theta}_{UR}) \cdot \frac{\partial g'}{\partial \theta}(\hat{\theta}_{UR}) \right]^{-1} g(\hat{\theta}_{UR}) = [-0.3]' \cdot [1' \cdot 47.0588^{-1} \cdot 1]^{-1} \cdot [-0.3] = 4.2352$$

Поскольку наблюдаемое значение статистики Вальда превосходит критическое значение 3.8414, то гипотеза  $H_0$  должна быть отвергнута.

$$I(\hat{\theta}_R) = \frac{n}{\hat{\lambda}_R} = \frac{80}{2} = 40$$

$$\frac{\partial l}{\partial \theta}(\hat{\theta}_R) = \frac{\sum_{i=1}^n x_i}{\hat{\lambda}_R} - n = \frac{80 \cdot 1.7}{2} - 80 = -12$$

$$LM_{\text{набл}} = \left[ \frac{\partial l}{\partial \theta}(\hat{\theta}_R) \right]' \cdot I^{-1}(\hat{\theta}_R) \cdot \left[ \frac{\partial l}{\partial \theta}(\hat{\theta}_R) \right] = [-12]' \cdot [40]^{-1} \cdot [-12] = 3.6$$

Согласно тесту множителей Лагранжа, основная гипотеза  $H_0$  не может быть отвергнута.

5.8.

5.9.

5.10.

5.11.

5.12.

5.13.

5.14.  $\hat{p}_1 = X_1/n$ ,  $\hat{p}_2 = X_2/n$ .

5.15. Функция правдоподобия:

$$\mathcal{L} = \prod_{i=1}^n \frac{\theta(\ln X_i)^{\theta-1}}{X_i}$$

Логарифм функции правдоподобия:

$$\ln \mathcal{L} = \sum_{i=1}^n [\ln(\theta(\ln X_i)^{\theta-1}) - \ln X_i] = \sum_{i=1}^n [\ln \theta + (\theta-1) \ln \ln X_i - \ln X_i] = n \ln \theta + (\theta-1) \sum_{i=1}^n \ln \ln X_i - \sum_{i=1}^n \ln X_i$$

$$\frac{\mathbb{P} \ln \mathcal{L}}{\mathbb{P} \theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln \ln X_i$$

FOC:

$$\frac{\mathbb{P} \ln \mathcal{L}}{\mathbb{P} \theta} = 0 \Rightarrow \frac{n}{\theta} = - \sum_{i=1}^n \ln \ln X_i \Rightarrow \hat{\theta}_{\text{ML}} = - \frac{n}{\sum_{i=1}^n \ln \ln X_i}$$

Подставим имеющиеся данные:  $-\frac{n}{\sum \ln \ln X_i} = -\frac{100}{-30} = \frac{10}{3}$ .

**(b) (3 балла)** Так как оценки ММП асимптотически нормальны, то для нахождения доверительного интервала достаточно найти стандартное отклонение параметра и домножить на квантиль двухстороннего распределения:  $\mathbb{P} \left( \left\{ |\hat{\theta} - \theta| \leq z_{0,025} \sqrt{\text{Var}(\hat{\theta})} \right\} \right) = 0,95$ . Известно, что  $\widehat{\text{Var}}(\hat{\theta}) = -\mathbf{H}^{-1}|_{\hat{\theta}}$ . Матрица  $\mathbf{H}$  — это матрица вторых производных логарифма функции правдоподобия.

$$\mathbf{H} = \frac{\mathbb{P}^2 \ln \mathcal{L}}{\mathbb{P} \theta^2} = -\frac{n}{\theta^2} \Rightarrow -\mathbf{H}^{-1} = \frac{\theta^2}{n} \Rightarrow \widehat{\text{Var}}(\hat{\theta}) = \frac{100/9}{100} = \frac{1}{9} \Rightarrow \hat{\sigma}_{\theta} = \frac{1}{3}$$

Следовательно, с вероятностью 0,95  $\theta$  лежит в интервале  $\frac{10}{3} \pm 1,96 \cdot \frac{1}{3} \approx \frac{10}{3} \pm \frac{2}{3}$ , или  $[2,680; 3,987]$ .

**(c) (3 × 3 = 9 баллов)** Тест Вальда выглядит следующим образом:

$$W = (\mathbf{c}(\theta) - \mathbf{q})' (\mathbf{C} \mathbf{I}^{-1}(\theta) \mathbf{C}')^{-1} (\mathbf{c}(\theta) - \mathbf{q}) \stackrel{\mathcal{H}_0}{\sim} \chi_r^2$$

За  $\mathbf{C}$  обозначено  $\frac{\mathbb{P} \mathbf{c}(\theta)}{\mathbb{P} \theta}$ , за  $\mathbf{I}$  — информационная матрица Фишера ( $\mathbf{I}(\theta) = -\mathbb{E} \left( \frac{\mathbb{P}^2 \ln \mathcal{L}}{\mathbb{P} \theta^2} \right)$ ). В данном случае  $\theta = \theta$ , и нулевая гипотеза  $\mathbf{c}(\theta) = \mathbf{q}$  выглядит как  $\theta = 1$  ( $\mathbf{c}(\theta) = \theta$ ) — одномерный случай, одна степень

свободы хи-квадрата,  $W \stackrel{\mathcal{H}_0}{\sim} \chi_1^2$ .  $\mathbf{c}'(\theta) = 1$ , поэтому расчётная статистика выглядит следующим образом:

$$W = (\hat{\theta} - \theta_0) \frac{n}{\theta^2} (\hat{\theta} - \theta_0) = \left( \frac{10}{3} - 1 \right) \cdot \frac{100}{100/9} \cdot \left( \frac{10}{3} - 1 \right) = 49$$

Тест отношения правдоподобия:

$$LR = -2(\ln \mathcal{L}_R - \ln \mathcal{L}_{UR}) \stackrel{\mathcal{H}_0}{\sim} \chi_r^2$$

$$\begin{aligned} LR &= -2 \left( \left[ n \ln \theta_0 + (\theta_0 - 1) \sum_{i=1}^n \ln \ln X_i - \sum_{i=1}^n \ln X_i \right] - \left[ n \ln \hat{\theta} + (\hat{\theta} - 1) \sum_{i=1}^n \ln \ln X_i - \sum_{i=1}^n \ln X_i \right] \right) = \\ &= -2 \left( \cancel{100 \ln 1} + (1 - 1) \cancel{(-30)} - 100 \ln \frac{10}{3} - \left( \frac{10}{3} - 1 \right) (-30) \right) = -2 \left( -100 \ln \frac{10}{3} + \frac{7}{3} \cdot 30 \right) \approx 100,8 \end{aligned}$$

Тест множителей Лагранжа:

$$LM = \mathbf{S}(\theta_0)' \mathbf{I}^{-1}(\theta_0) \mathbf{S}(\theta_0) \stackrel{\mathcal{H}_0}{\sim} \chi_r^2$$

$\mathbf{S} = \frac{\mathbb{P} \ln \mathcal{L}}{\mathbb{P} \theta} \Big|_{\theta_0}$ . В точке  $\theta_0$  значение частной производной логарифма функции правдоподобия равно  $\frac{100}{1} - 30 = 70$ ,  $\mathbf{I}^{-1}(\theta_0) = \frac{\theta_0^2}{n} = \frac{1}{100}$ , откуда

$$LM = 70 \cdot \frac{1}{100} \cdot 70 = 49$$

Для уровня значимости 5 % критическое значение  $\chi_1^2$  равно  $\approx 3,84$ , поэтому во всех трёх тестах гипотеза  $\mathcal{H}_0: \theta = 1$  отвергается.

5.16.

$$\theta = \begin{pmatrix} \mu \\ \sigma^2 \end{pmatrix}, \quad \mathcal{L} = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left( -\frac{(X_i - \mu)^2}{2\sigma^2} \right), \quad \ln \mathcal{L} = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$$

$$\text{FOC: } \frac{\mathbb{P} \ln \mathcal{L}}{\mathbb{P} \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu), \quad \frac{\mathbb{P} \ln \mathcal{L}}{\mathbb{P}(\sigma^2)} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (X_i - \mu)^2$$

$$\frac{\mathbb{P}^2 \ln \mathcal{L}}{\mathbb{P} \mu^2} = -\frac{n}{\sigma^2}, \quad \frac{\mathbb{P}^2 \ln \mathcal{L}}{\mathbb{P} \mu \mathbb{P}(\sigma^2)} = -\frac{1}{(\sigma^2)^2} \sum_{i=1}^n (X_i - \mu), \quad \frac{\mathbb{P}^2 \ln \mathcal{L}}{\mathbb{P}(\sigma^2)^2} = \frac{n}{2(\sigma^2)^2} - \frac{1}{(\sigma^2)^3} \sum_{i=1}^n (X_i - \mu)^2$$

Т. к. даны  $\sum X_i$  и  $\sum X_i^2$ , то можно вывести, что  $\sum (X_i - \mu)^2 = \sum X_i^2 - \sum 2\mu X_i + \sum \mu^2 = \sum X_i^2 - 2\mu \sum X_i + n\mu^2$ .

Из условий первого порядка следует, что ММП-оценка матожидания  $\hat{\mu}_{\text{ML}}$  — это выборочное среднее, а дисперсии  $\hat{\sigma}_{\text{ML}}^2$  — выборочная дисперсия (без коррекции на одну степень свободы):

$$\hat{\mu}_{\text{ML}} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{100}{100} = 1, \quad \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 = \frac{1}{100} (900 - 2 \cdot 1 \cdot 100 + 100 \cdot 1^2) = \frac{800}{100} = 8$$

(b) (2 + 2 = 4 балла)

$$\mathbf{I}(\theta) = -\mathbb{E} \left( \frac{\mathbb{P}^2 \ln \mathcal{L}}{\mathbb{P} \theta^2} \right), \quad \mathbf{I}(\hat{\theta}) = \begin{pmatrix} \frac{n}{\hat{\sigma}^2} & 0 \\ 0 & \frac{n}{2(\hat{\sigma}^2)^2} \end{pmatrix} = \begin{pmatrix} \frac{100}{8} & 0 \\ 0 & \frac{100}{128} \end{pmatrix}, \quad \mathbf{I}^{-1}(\hat{\theta}) = \begin{pmatrix} \frac{2}{25} & 0 \\ 0 & \frac{32}{25} \end{pmatrix}$$

Так как ММП-оценки асимптотически нормальны, то 95%-й доверительный интервал для вектора неизвестных параметров выглядит как

$$\begin{pmatrix} \hat{\mu} \pm z_{\frac{\alpha}{2}} \sqrt{\widehat{\text{Var}}(\hat{\mu})} \\ \hat{\sigma}^2 \pm z_{\frac{\alpha}{2}} \sqrt{\widehat{\text{Var}}(\hat{\mu})} \end{pmatrix} \approx \begin{pmatrix} 1 \pm 1,96 \sqrt{\frac{2}{25}} \\ 8 \pm 1,96 \sqrt{\frac{32}{25}} \end{pmatrix} \approx \begin{pmatrix} [0,446; 1,554] \\ [5,783; 10,217] \end{pmatrix}$$

**(с) (3 × 3 = 9 баллов)**

Тест Вальда:

$$W = (c(\sigma^2) - \sigma_0^2)'(CI^{-1}(\theta)C')^{-1}(c(\sigma^2) - \sigma_0^2) \stackrel{\mathcal{H}_0}{\sim} \chi_r^2$$

$\frac{\mathbb{P}c}{\mathbb{P}\sigma^2} = 1$ , поэтому

$$W = (8 - 1)^2 \frac{n}{2(\sigma^2)^2} = 49 \cdot \frac{100}{128} \approx 38,28$$

Тест отношения правдоподобия:

$$LR = -2(\ln \mathcal{L}_R - \ln \mathcal{L}_{UR}) \stackrel{\mathcal{H}_0}{\sim} \chi_r^2$$

$$\begin{aligned} LR = -2(\ln \mathcal{L}(\sigma_0^2) - \ln \mathcal{L}(\hat{\sigma}^2)) &= -2 \left( -\frac{n}{2} \ln \sigma_0^2 - \frac{1}{2\sigma_0^2} \cdot 800 + \frac{n}{2} \ln \hat{\sigma}^2 + \frac{1}{2\hat{\sigma}^2} \cdot 800 \right) = \\ &= -2 \left( -50 \ln 1 - \frac{1}{2} \cdot 800 + 50 \ln 8 + \frac{1}{16} \cdot 800 \right) \approx 492 \end{aligned}$$

Тест множителей Лагранжа:

$$\begin{aligned} LM &= S(\sigma_0^2)'I^{-1}(\sigma_0^2)S(\sigma_0^2) \stackrel{\mathcal{H}_0}{\sim} \chi_r^2 \\ I(\sigma_0^2) &= \frac{n}{2(\sigma_0^2)^2} = 50, \quad S(\sigma_0^2) = \frac{\mathbb{P} \ln \mathcal{L}}{\mathbb{P}(\sigma^2)} \Big|_{\sigma_0^2} = -\frac{100}{2} + \frac{1}{2} \cdot 800 = 350 \\ LM &= 350^2 \cdot \frac{1}{50} = 2450 \end{aligned}$$

Для уровня значимости 5 % критическое значение  $\chi_1^2$  равно  $\approx 3,84$ , поэтому во всех трёх тестах гипотеза  $\mathcal{H}_0: \sigma^2 = 1$  отвергается.

**(d) (3 × 3 = 9 баллов)**

Тест Вальда выглядит следующим образом:

$$W = (\mathbf{c}(\hat{\theta}) - \mathbf{q})'(CI^{-1}(\hat{\theta})C')^{-1}(\mathbf{c}(\hat{\theta}) - \mathbf{q}) \stackrel{\mathcal{H}_0}{\sim} \chi_r^2$$

За  $\mathbf{C}$  обозначено  $\frac{\mathbb{P}\mathbf{c}(\theta)}{\mathbb{P}\theta}$ , за  $\mathbf{I}$  — информационная матрица Фишера ( $\mathbf{I}(\theta) = -\mathbb{E} \left( \frac{\mathbb{P}^2 \ln \mathcal{L}}{\mathbb{P}\theta^2} \right)$ ). В данном случае нулевая гипотеза  $\mathbf{c}(\theta) = \mathbf{q}$  записывается как  $\mathbf{c}(\theta) = \begin{pmatrix} \mu \\ \sigma^2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$ , поэтому все статистики имеют две степени свободы хи-квадрата.  $\mathbf{C} = \frac{\mathbb{P}\mathbf{c}}{\mathbb{P}\theta} = \begin{pmatrix} \frac{\mathbb{P}c_1}{\mathbb{P}\mu} & \frac{\mathbb{P}c_2}{\mathbb{P}\sigma^2} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ ,  $\mathbf{c}(\theta) - \mathbf{q} = \begin{pmatrix} 1 \\ 8 \end{pmatrix} - \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 7 \end{pmatrix}$ , поэтому расчётная статистика выглядит следующим образом:

$$W = (-1 \quad 7) \left[ \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \frac{100}{8} & 0 \\ 0 & \frac{100}{128} \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right] \begin{pmatrix} -1 \\ 7 \end{pmatrix} = (-1 \quad 7) \begin{pmatrix} \frac{25}{2} & 0 \\ 0 & \frac{25}{32} \end{pmatrix} \begin{pmatrix} -1 \\ 7 \end{pmatrix} = 50,78$$

Тест отношения правдоподобия:

$$LR = -2(\ln \mathcal{L}_R - \ln \mathcal{L}_{UR}) \stackrel{\mathcal{H}_0}{\sim} \chi_r^2$$

$$\begin{aligned}
LR &= -2(\ln \mathcal{L}(\mathbf{q}) - \ln \mathcal{L}(\hat{\boldsymbol{\theta}})) = \\
&= -2 \left( -\frac{n}{2} \ln \sigma_0^2 - \frac{1}{2\sigma_0^2} \left( \sum X_i^2 - 2\mu_0 \sum X_i + n\mu_0^2 \right) + \frac{n}{2} \ln \hat{\sigma}^2 + \frac{1}{2\hat{\sigma}^2} \left( \sum X_i^2 - 2\hat{\mu} \sum X_i + n\hat{\mu}^2 \right) \right) = \\
&= -2 \left( -\frac{100}{2} \ln 1 - \frac{1}{2} (900 - 2 \cdot 2 \cdot 100 + 100 \cdot 2^2) + \frac{100}{2} \ln 8 + \frac{1}{16} (900 - 2 \cdot 1 \cdot 100 + 100 \cdot 1) \right) \approx 592
\end{aligned}$$

Тест множителей Лагранжа:

$$\begin{aligned}
LM &= \mathbf{S}(\boldsymbol{\theta}_0)' \mathbf{I}^{-1}(\boldsymbol{\theta}_0) \mathbf{S}(\boldsymbol{\theta}_0) \stackrel{\mathcal{H}_0}{\approx} \chi_r^2 \\
\mathbf{I}(\boldsymbol{\theta}_0) &= \begin{pmatrix} \frac{n}{\sigma_0^2} & 0 \\ 0 & \frac{n}{2(\sigma_0^2)^2} \end{pmatrix} = \begin{pmatrix} 100 & 0 \\ 0 & 50 \end{pmatrix}, \quad \mathbf{I}^{-1}(\boldsymbol{\theta}_0) = \begin{pmatrix} \frac{1}{100} & 0 \\ 0 & \frac{1}{50} \end{pmatrix} \\
\mathbf{S}(\boldsymbol{\theta}_0) &= \begin{pmatrix} \frac{1}{\sigma_0^2} (100 - 100\mu_0) \\ -\frac{100}{2\sigma_0^2} + \frac{1}{2(\sigma_0^2)^2} (900 - 200\mu_0 + 100\mu_0^2) \end{pmatrix} = \begin{pmatrix} -100 \\ 400 \end{pmatrix} \\
LM &= (-100 \quad 400) \begin{pmatrix} \frac{1}{100} & 0 \\ 0 & \frac{1}{50} \end{pmatrix} \begin{pmatrix} -100 \\ 400 \end{pmatrix} = 3300
\end{aligned}$$

Для уровня значимости 5 % критическое значение  $\chi_2^2$  равно  $\approx 5,99$ , поэтому во всех трёх тестах гипотеза  $\mathcal{H}_0: \boldsymbol{\theta} = \boldsymbol{\theta}_0$  отвергается.

5.17. Можно решать перебором вариантов.

6.1.  $f(x)$  чётная,  $\mathbb{E}(X) = 0$ ,  $\text{Var}(X) = \pi^2/3$ , логистическое похоже на  $N(0, \pi^2/3)$

6.2.  $\ln \left( \frac{\mathbb{P}(y_i=1)}{\mathbb{P}(y_i=0)} \right) = \beta_1 + \beta_2 x_i$ .

6.3.

6.4.

6.5.

6.6. Для краткости введем следующие обозначения:  $y_i = \text{honey}_i$ ,  $d_i = \text{bee}_i$ <sup>1</sup>.

1. Функция правдоподобия имеет следующий вид:

$$\begin{aligned}
L(\beta_1, \beta_2) &= \prod_{i=1}^n \mathbb{P}_{\beta_1, \beta_2} (\{Y_i = y_i\}) = \\
&= \prod_{i:y_i=0} \mathbb{P}_{\beta_1, \beta_2} (\{Y_i = 1\}) \cdot \prod_{i:y_i=1} \mathbb{P}_{\beta_1, \beta_2} (\{Y_i = 0\}) = \\
&= \prod_{i:y_i=1} \Lambda(\beta_1 + \beta_2 d_i) \cdot \prod_{i:y_i=0} [1 - \Lambda(\beta_1 + \beta_2 d_i)] = \\
&= \prod_{i:y_i=1, d_i=1} \Lambda(\beta_1 + \beta_2) \cdot \prod_{i:y_i=1, d_i=0} \Lambda(\beta_1) \cdot \prod_{i:y_i=0, d_i=1} [1 - \Lambda(\beta_1 + \beta_2)] \cdot \\
&\quad \cdot \prod_{i:y_i=0, d_i=0} [1 - \Lambda(\beta_1)] = \\
&= \Lambda(\beta_1 + \beta_2)^{\#\{i:y_i=1, d_i=1\}} \cdot \Lambda(\beta_1)^{\#\{i:y_i=1, d_i=0\}} \cdot [1 - \Lambda(\beta_1 + \beta_2)]^{\#\{i:y_i=0, d_i=1\}} \cdot \\
&\quad \cdot [1 - \Lambda(\beta_1)]^{\#\{i:y_i=0, d_i=0\}} \quad (1.33)
\end{aligned}$$

где

$$\Lambda(x) = \frac{e^x}{1 + e^x} \quad (1.34)$$

логистическая функция распределения,  $\#A$  означает число элементов множества  $A$ .

2. Введём следующие обозначения:

$$a := \Lambda(\beta_1) \quad (1.35)$$

---

<sup>1</sup> $Y_i$  — случайный Мёд,  $y_i$  — реализация случайного Мёда (наблюдаемый Мёд)

$$b := \Lambda(\beta_1 + \beta_2) \quad (1.36)$$

Тогда с учетом имеющихся наблюдений функция правдоподобия принимает вид:

$$L(a, b) = b^{12} \cdot a^{32} \cdot [1 - b]^{36} \cdot [1 - a]^{20}$$

Логарифмическая функция правдоподобия:

$$l(a, b) = \ln L(a, b) = 12 \ln b + 32 \ln a + 36 \ln[1 - b] + 20 \ln[1 - a]$$

Решая систему уравнений правдоподобия

$$\begin{cases} \frac{\partial l}{\partial a} = \frac{32}{a} - \frac{20}{1-a} = 0 \\ \frac{\partial l}{\partial b} = \frac{12}{b} - \frac{36}{1-b} = 0 \end{cases}$$

получаем  $\hat{a} = \frac{8}{13}$ ,  $\hat{b} = \frac{1}{4}$ . Из формул (1.34) и (1.35), находим  $\hat{\beta}_{1,UR} = \ln\left(\frac{\hat{a}}{1-\hat{a}}\right) = \ln\left(\frac{8}{5}\right) = 0.47$ . Далее, из (1.34) и (1.36) имеем  $\hat{\beta}_{1,UR} + \hat{\beta}_{2,UR} = \ln\left(\frac{\hat{b}}{1-\hat{b}}\right)$ . Следовательно,  $\hat{\beta}_{2,UR} = \ln\left(\frac{\hat{b}}{1-\hat{b}}\right) - \hat{\beta}_{1,UR} = \ln\left(\frac{1}{3}\right) - \ln\left(\frac{8}{5}\right) = -1.57$ .

3. Гипотеза, состоящая в том, что «правильность Мёда не связана с правильностью пчёл» формализуется как  $H_0 : \beta_2 = 0$ . Протестируем данную гипотезу при помощи теста отношения правдоподобия. Положим в функции правдоподобия  $L(\beta_1, \beta_2)$   $\beta_2 = 0$ . Тогда с учетом (1.35) и (1.36) получим

$$L(a, b = a) = a^{32+12} \cdot [1 - a]^{20+36}$$

В этом случае логарифмическая функция правдоподобия имеет вид:

$$l(a, b = a) := L(a, b = a) = 44 \ln a + 56 \ln[1 - a]$$

Решаем уравнение правдоподобия

$$\frac{\partial l}{\partial a} = \frac{44}{a} - \frac{56}{1-a} = 0$$

и получаем  $\hat{a} = \frac{11}{25}$ . Следовательно, согласно (1.34) и (1.35),  $\hat{\beta}_{1,R} = -0.24$  и  $\hat{\beta}_{2,R} = 0$ .

Статистика отношения правдоподобия имеет вид:

$$LR = -2(l(\hat{\beta}_{1,R}, \hat{\beta}_{2,R}) - l(\hat{\beta}_{1,UR}, \hat{\beta}_{2,UR}))$$

и имеет асимптотическое  $\chi^2$  распределение с числом степеней свободы, равным числу ограничений, составляющих гипотезу  $H_0$ , т.е. в данном случае  $LR \stackrel{a}{\sim} \chi_1^2$ .

Находим наблюдаемое значение статистики отношения правдоподобия:

$$\begin{aligned} l(\hat{\beta}_{1,R}, \hat{\beta}_{2,R}) &= l(\hat{a}_R, \hat{b}_R = \hat{a}_R) = 44 \ln \hat{a}_R + 56 \ln[1 - \hat{a}_R] = \\ &= 44 \ln \left[ \frac{11}{25} \right] + 56 \ln \left[ 1 - \frac{11}{25} \right] = -68.59 \end{aligned} \quad (1.37)$$

$$\begin{aligned} l(\hat{\beta}_{1,UR}, \hat{\beta}_{2,UR}) &= l(\hat{a}_{UR}, \hat{b}_{UR}) = \\ &= 12 \ln \hat{b}_{UR} + 32 \ln \hat{a}_{UR} + 36 \ln[1 - \hat{b}_{UR}] + 20 \ln[1 - \hat{a}_{UR}] = \\ &= 12 \ln \left[ \frac{1}{4} \right] + 32 \ln \left[ \frac{8}{13} \right] + 36 \ln \left[ 1 - \frac{1}{4} \right] + 20 \ln \left[ 1 - \frac{8}{13} \right] = -61.63 \end{aligned} \quad (1.38)$$

Следовательно,  $LR_{\text{набл}} = -2(-68.59 + 61.63) = 13.92$ , при этом критическое значение  $\chi^2$  распределения с одной степенью свободы для 5% уровня значимости равна 3.84. Значит, на основании теста отношения правдоподобия гипотеза  $H_0 : \beta_2 = 0$  должна быть отвергнута. Таким образом, данные показывают, что, в действительности, правильность мёда связана с правильностью пчёл.

4.

$$\begin{aligned} \hat{\mathbb{P}}\{honey = 0 | bee = 0\} &= 1 - \hat{\mathbb{P}}\{honey = 1 | bee = 0\} = \\ &= 1 - \frac{\exp\{\hat{\beta}_{1,UR} + \hat{\beta}_{2,UR} \cdot 0\}}{1 + \exp\{\hat{\beta}_{1,UR} + \hat{\beta}_{2,UR} \cdot 0\}} = \\ &= 1 - \frac{\exp\{\ln(\frac{8}{5})\}}{1 + \exp\{\ln(\frac{8}{5})\}} = 1 - 0.62 = 0.38 \quad (1.39) \end{aligned}$$

7.1.

7.2. увеличить количество наблюдений, уменьшить дисперсию случайной ошибки

7.3.

7.4.

7.5.

7.6.

7.7.

7.8.  $r^* = -1/2$ 7.9.  $r^* = -1/3$ 

8.1.

8.2. Поделить зависимую переменную и каждый регрессор, включая единичный столбец, на  $|x_i|$ .8.3. Поделить зависимую переменную и каждый регрессор, включая единичный столбец, на  $\sqrt{|x_i|}$ .8.4.  $\text{Var}(\varepsilon_i) = cx_i^4$ 8.5.  $\text{Var}(\varepsilon_i) = cx_i$ 

8.6. По графику видно, что с увеличением общей площади увеличивается разброс цены. Поэтому разумно, например, рассмотреть следующие подходы:

1. Перейти к логарифмам, т.е. оценивать модель  $\ln price_i = \beta_1 + \beta_2 \ln totsp_i + \varepsilon_i$ 2. Оценивать квантильную регрессию. В ней угловые коэффициенты линейной зависимости будут отличаться для разных квантилей переменной  $price$ .3. Обычную модель линейной регрессии с гетероскедастичностью вида  $\text{Var}(\varepsilon_i) = \sigma^2 totsp_i^2$ 

8.7.

8.8. Протестируем гетероскедастичность ошибок при помощи теста Голдфелда-Квандта.  $H_0 : \text{Var}(\varepsilon_i) = \sigma^2$ ,  $H_a : \text{Var}(\varepsilon_i) = f(x_i)$ 1. Тестовая статистика  $GQ = \frac{RSS_3/(n_3-k)}{RSS_1/(n_1-k)}$ , где  $n_1 = 11$  — число наблюдений в первой подгруппе,  $n_3 = 11$  — число наблюдений в последней подгруппе,  $k = 3$  — число факторов в модели, считая единичный столбец.2. Распределение тестовой статистики при верной  $H_0$ :  $GQ \sim F_{n_3-k, n_1-k}$ 3. Наблюдаемое значение  $GQ_{obs} = 1.41$ 4. Область, в которой  $H_0$  не отвергается:  $GQ \in [0; 3.44]$ 5. Статистический вывод: поскольку  $GQ_{obs} \in [0; 3.44]$ , то на основании имеющихся наблюдений на уровне значимости 5% основная гипотеза  $H_0$  не может быть отвергнута. Таким образом, тест Голдфелда-Квандта не выявил гетероскедастичность.8.9. Протестируем гетероскедастичность ошибок при помощи теста Голдфелда-Квандта.  $H_0 : \text{Var}(\varepsilon_i) = \sigma^2$ ,  $H_a : \text{Var}(\varepsilon_i) = f(x_i)$



1. Тестовая статистика  $GQ = \frac{RSS_3/(n_3-k)}{RSS_1/(n_1-k)}$ , где  $n_1 = 21$  — число наблюдений в первой подгруппе,  $n_3 = 21$  — число наблюдений в последней подгруппе,  $k = 3$  — число факторов в модели, считая единичный столбец.
2. Распределение тестовой статистики при верной  $H_0$ :  $GQ \sim F_{n_3-k, n_1-k}$
3. Наблюдаемое значение  $GQ_{obs} = 6.49$
4. Область, в которой  $H_0$  не отвергается:  $GQ \in [0; 3.12]$
5. Статистический вывод: поскольку  $GQ_{obs} \notin [0; 3.12]$ , то на основании имеющихся наблюдений на уровне значимости 1% основная гипотеза  $H_0$  отвергается. Таким образом, тест Голдфельда-Квандта выявил гетероскедастичность.

8.10. Протестируем гетероскедастичность ошибок при помощи теста Голдфельда-Квандта.  $H_0 : \text{Var}(\varepsilon_i) = \sigma^2$ ,  $H_a : \text{Var}(\varepsilon_i) = f(x_i)$

1. Тестовая статистика  $GQ = \frac{RSS_3/(n_3-k)}{RSS_1/(n_1-k)}$ , где  $n_1 = 11$  — число наблюдений в первой подгруппе,  $n_3 = 11$  — число наблюдений в последней подгруппе,  $k = 3$  — число факторов в модели, считая единичный столбец.
2. Распределение тестовой статистики при верной  $H_0$ :  $GQ \sim F_{n_3-k, n_1-k}$
3. Наблюдаемое значение  $GQ_{obs} = 2.88$
4. Область, в которой  $H_0$  не отвергается:  $GQ \in [0; 3.44]$
5. Статистический вывод: поскольку  $GQ_{obs} \in [0; 3.44]$ , то на основании имеющихся наблюдений на уровне значимости 5% основная гипотеза  $H_0$  не может быть отвергнута. Таким образом, тест Голдфельда-Квандта не выявил гетероскедастичность.

8.11. Протестируем гетероскедастичность ошибок при помощи теста Голдфельда-Квандта.  $H_0 : \text{Var}(\varepsilon_i) = \sigma^2$ ,  $H_a : \text{Var}(\varepsilon_i) = f(x_i)$

1. Тестовая статистика  $GQ = \frac{RSS_3/(n_3-k)}{RSS_1/(n_1-k)}$ , где  $n_1 = 21$  — число наблюдений в первой подгруппе,  $n_3 = 21$  — число наблюдений в последней подгруппе,  $k = 3$  — число факторов в модели, считая единичный столбец.
2. Распределение тестовой статистики при верной  $H_0$ :  $GQ \sim F_{n_3-k, n_1-k}$
3. Наблюдаемое значение  $GQ_{obs} = 5.91$
4. Область, в которой  $H_0$  не отвергается:  $GQ \in [0; 2.21]$
5. Статистический вывод: поскольку  $GQ_{obs} \notin [0; 2.21]$ , то на основании имеющихся наблюдений на уровне значимости 5% основная гипотеза  $H_0$  отвергается. Таким образом, тест Голдфельда-Квандта выявил гетероскедастичность.

8.12. Протестируем гетероскедастичность ошибок при помощи теста Уайта.  $H_0 : \text{Var}(\varepsilon_i) = \sigma^2$ ,  $H_a : \text{Var}(\varepsilon_i) = \delta_1 + \delta_2 x_i + \delta_3 z_i + \delta_4 x_i^2 + \delta_5 z_i^2 + \delta_6 x_i z_i$ .

1. Тестовая статистика  $W = n \cdot R_{aux}^2$ , где  $n$  — число наблюдений,  $R_{aux}^2$  — коэффициент детерминации для вспомогательной регрессии.
2. Распределение тестовой статистики при верной  $H_0$ :  $W \sim \chi_{k_{aux}-1}^2$ , где  $k_{aux} = 6$  — число регрессоров во вспомогательной регрессии, считая константу.
3. Наблюдаемое значение тестовой статистики:  $W_{obs} = 18$
4. Область, в которой  $H_0$  не отвергается:  $W \in [0; W_{crit}] = [0; 11.07]$

5. Статистический вывод: поскольку  $W_{obs} \notin [0; 11.07]$ , то на основании имеющихся наблюдений на уровне значимости 5% основная гипотеза  $H_0$  отвергается. Таким образом, тест Уайта выявил гетероскедастичность.

8.13.

8.14.

8.15.

8.16.

8.17.

8.18.

8.19.

8.20.

8.21.

8.22.

8.23. 0.0752, 5, 10

8.24.  $k(k+1)/2$ 

8.25.

8.26. Известно, что оценки параметров, получаемые по обобщённому методу наименьших квадратов,

являются наилучшими, поэтому:  $\delta^2$

$$\begin{bmatrix} x_1 & 0 \dots 0 & 0 \\ 0 & & 0 \\ & \dots & \\ 0 & & 0 \\ 0 & 0 \dots 0 & x_n \end{bmatrix}$$

8.27.

$$\begin{aligned} \text{Cov}(\hat{\beta}_{GLS}, \varepsilon) &= \text{Cov}((X^T \Sigma^{-1} X)^{-1} X^T \Sigma^{-1} y, \varepsilon) = \\ &= \text{Cov}((X^T \Sigma^{-1} X)^{-1} X^T \Sigma^{-1} \varepsilon, \varepsilon) = \\ &= (X^T \Sigma^{-1} X)^{-1} X^T \Sigma^{-1} \text{Cov}(\varepsilon, \varepsilon) = \\ &= (X^T \Sigma^{-1} X)^{-1} X^T \Sigma^{-1} \Sigma = (X^T \Sigma^{-1} X)^{-1} X^T \quad (1.40) \end{aligned}$$

8.28. Для нахождения эффективной оценки воспользуемся взвешенным методом наименьших квадратов. Разделим каждое из уравнений  $y_i = \beta_1 + \varepsilon$  на корень из дисперсии  $\varepsilon_i$  с тем, чтобы ошибки в полученных уравнениях имели равные дисперсии (в этом случае можно будет сослаться на т. Гаусса-Маркова). Итак, после деления  $i$ -го уравнения на величину  $\sqrt{x_i}/\sigma_\varepsilon$ , мы получаем:

$$\begin{bmatrix} y_1 \sqrt{x_1}/\sigma_\varepsilon \\ y_2 \sqrt{x_2}/\sigma_\varepsilon \\ \dots \\ y_n \sqrt{x_n}/\sigma_\varepsilon \end{bmatrix} = \beta_1 \begin{bmatrix} \sqrt{x_1}/\sigma_\varepsilon \\ \sqrt{x_2}/\sigma_\varepsilon \\ \dots \\ \sqrt{x_n}/\sigma_\varepsilon \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \sqrt{x_1}/\sigma_\varepsilon \\ \varepsilon_2 \sqrt{x_2}/\sigma_\varepsilon \\ \dots \\ \varepsilon_n \sqrt{x_n}/\sigma_\varepsilon \end{bmatrix}$$

Поскольку условия т. Гаусса-Маркова для последней модели выполнены, то МНК-оценка для последней модели будет наиболее эффективной. Поэтому

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (y_i \sqrt{x_i}/\sigma_\varepsilon)(\sqrt{x_i}/\sigma_\varepsilon)}{\sum_{i=1}^n (\sqrt{x_i}/\sigma_\varepsilon)^2} = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2}$$

8.29.

8.30. В предположении о гомоскедастичности,  $\gamma_2 = 0$ , оценка правдоподобия совпадает с МНК-оценкой, значит  $\hat{\beta} = \sum y_i x_i / \sum x_i^2$ . И  $\hat{s}_i^2 = RSS/n$ , значит  $\hat{\gamma}_1 = \ln(RSS/n)$ .

9.1.

9.2.

9.3.

9.4.

9.5.

9.6.

9.7. чтобы избежать переполнения при подсчете произведения всех  $y_i$

9.8.

9.9.

10.1.  $u_i^2 = \varepsilon_i^2 = 1$ ,  $\mathbb{E}(\hat{\beta} \mid x_1 = 0, x_2 = 1) = 0.2\beta$ ,  $\mathbb{E}(\hat{\beta} \mid x_1 = 0, x_2 = 2) = 0.8\beta$ . Интуитивно объясняем: рисуем прямую по двум точкам. Мы знаем абсциссы точек с точностью  $\pm 1$ . Если точки близки, то это может сильно менять оценку наклона, если точки далеки, то случайность слабо влияет на наклон.

10.2.

10.3.

10.4.

11.1.

11.2.

1. Процесс  $AR(2)$ , т.к. две первые частные корреляции значимо отличаются от нуля, а гипотезы о том, что каждая последующая равна нулю не отвергаются.
2. Можно использовать одну из двух статистик

$$\text{Ljung-Box} = n(n+2) \sum_{k=1}^3 \frac{\hat{\rho}_k^2}{n-k} = 0.4289$$

$$\text{Box-Pierce} = n \sum_{k=1}^3 \hat{\rho}_k^2 = 0.4076$$

Критическое значение хи-квадрат распределения с 3-мя степенями свободы для  $\alpha = 0.05$  равно  $\chi_{3,crit}^2 = 7.8147$ . Вывод: гипотеза  $H_0$  об отсутствии корреляции ошибок модели не отвергается.

11.3.

1.  $H_0$ : ряд содержит единичный корень,  $\beta = 0$ ;  $H_0$ : ряд не содержит единичного корня,  $\beta < 0$
2.  $ADF = -0.4/0.1 = -4$ ,  $ADF_{crit} = -2.89$ ,  $H_0$  отвергается
3. Ряд стационарен
4. При верной  $H_0$  ряд не стационарен, и  $t$ -статистика имеет не  $t$ -распределение, а распределение Дики-Фуллера.

11.4.

11.5.

11.6.

11.7.

11.8.

11.9.

11.10.

1.  $\mathbb{E}(\varepsilon_t) = 0$ ,  $\text{Var}(\varepsilon_t) = \sigma^2/(1 - \rho^2)$
2.  $\text{Cov}(\varepsilon_t, \varepsilon_{t+h}) = \rho^h \cdot \sigma^2/(1 - \rho^2)$

3.  $\text{Corr}(\varepsilon_t, \varepsilon_{t+h}) = \rho^h$

11.11.

11.12. все линейные комбинации стационарны

11.13. Они будут примерно одинаковы. Оценка наклона определяется автоковариационной функцией.

11.14.

11.15.  $x_t = (1 - L)^t y_t$

11.16.  $F_n = L(1 + L)F_n$ , значит  $F_n = L^k(1 + L)^k F_n$  или  $F_{n+k} = (1 + L)^k F_n$

11.17. а - неверно, б - верно.

11.18.

11.19.

11.20.

11.21.

11.22.

11.23. 1, 2, 2

11.24.

11.25.

11.26.

11.27.

11.28.

11.29. 1. Поскольку имеют место соотношения  $\varepsilon_1 = \rho\varepsilon_0 + u_1$  и  $Y_1 = \mu + \varepsilon_1$ , то из условия задачи получаем, что  $\varepsilon_1 \sim N(0, \sigma^2/(1 - \rho^2))$  и  $Y_1 \sim N(\mu, \sigma^2/(1 - \rho^2))$ . Поэтому

$$f_{Y_1}(y_1) = \frac{1}{\sqrt{2\pi\sigma^2/(1 - \rho^2)}} \exp\left(-\frac{(y_1 - \mu)^2}{2\sigma^2/(1 - \rho^2)}\right).$$

Далее, найдем  $f_{Y_2|Y_1}(y_2|y_1)$ . Учитывая, что  $Y_2 = \rho Y_1 + (1 - \rho)\mu + u_2$ , получаем  $Y_2|\{Y_1 = y_1\} \sim N(\rho y_1 + (1 - \rho)\mu, \sigma^2)$ . Значит,

$$f_{Y_2|Y_1}(y_2|y_1) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_2 - \rho y_1 - (1 - \rho)\mu)^2}{2\sigma^2}\right).$$

Действуя аналогично, получаем, что для всех  $t \geq 2$  справедлива формула

$$f_{Y_t|Y_{t-1}}(y_t|y_{t-1}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_t - \rho y_{t-1} - (1 - \rho)\mu)^2}{2\sigma^2}\right).$$

Таким образом, находим функцию правдоподобия

$$L(\mu, \rho, \sigma^2) = f_{Y_T, \dots, Y_1}(y_T, \dots, y_1) = f_{Y_1}(y_1) \prod_{t=2}^T f_{Y_t|Y_{t-1}}(y_t|y_{t-1}),$$

где  $f_{Y_1}(y_1)$  и  $f_{Y_t|Y_{t-1}}(y_t|y_{t-1})$  получены выше.

2. Для нахождения неизвестных параметров модели запишем логарифмическую условную функцию правдоподобия:

$$\begin{aligned} l(\mu, \rho, \sigma^2|Y_1 = y_1) &= \sum_{t=2}^T \log f_{Y_t|Y_{t-1}}(y_t|y_{t-1}) = \\ &= -\frac{T-1}{2} \log(2\pi) - \frac{T-1}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{t=2}^T (y_t - \rho y_{t-1} - (1 - \rho)\mu)^2. \end{aligned}$$

Найдем производные функции  $l(\mu, \rho, \sigma^2|Y_1 = y_1)$  по неизвестным параметрам:

$$\frac{\partial l}{\partial \mu} = -\frac{1}{2\sigma^2} \sum_{t=2}^T 2(y_t - \rho y_{t-1} - (1 - \rho)\mu) \cdot (\rho - 1),$$

$$\frac{\partial l}{\partial \rho} = -\frac{1}{2\sigma^2} \sum_{t=2}^T 2(y_t - \rho y_{t-1} - (1 - \rho)\mu) \cdot (\mu - y_{t-1}),$$

$$\frac{\partial l}{\partial \sigma^2} = -\frac{T-1}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{t=2}^T (y_t - \rho y_{t-1} - (1 - \rho)\mu)^2.$$

Оценки неизвестных параметров модели могут быть получены как решение следующей системы уравнений:

$$\begin{cases} \frac{\partial l}{\partial \mu} = 0, \\ \frac{\partial l}{\partial \rho} = 0, \\ \frac{\partial l}{\partial \sigma^2} = 0. \end{cases}$$

Из первого уравнения системы получаем, что

$$\sum_{t=2}^T y_t - \hat{\rho} \sum_{t=2}^T y_{t-1} = (T-1)(1 - \hat{\rho})\hat{\mu},$$

откуда

$$\hat{\mu} = \frac{\sum_{t=2}^T y_t - \hat{\rho} \sum_{t=2}^T y_{t-1}}{(T-1)(1 - \hat{\rho})} = \frac{3 - \hat{\rho} \cdot 3}{4 \cdot (1 - \hat{\rho})} = \frac{3}{4}.$$

Далее, если второе уравнение системы переписать в виде

$$\sum_{t=2}^T (y_t - \hat{\mu} - \hat{\rho}(y_{t-1} - \hat{\mu}))(y_{t-1} - \hat{\mu}) = 0,$$

то легко видеть, что

$$\hat{\rho} = \frac{\sum_{t=2}^T (y_t - \hat{\mu})(y_{t-1} - \hat{\mu})}{\sum_{t=2}^T (y_{t-1} - \hat{\mu})^2}.$$

Следовательно,  $\hat{\rho} = -1/11 = -0.0909$ .

Наконец, из третьего уравнения системы

$$\hat{\sigma}^2 = \frac{1}{T-1} \sum_{t=2}^T (y_t - \hat{\rho} y_{t-1} - (1 - \hat{\rho})\hat{\mu})^2.$$

Значит,  $\hat{\sigma}^2 = 165/242 = 0.6818$ . Ответы:  $\hat{\mu} = 3/4 = 0.75$ ,  $\hat{\rho} = -1/11 = -0.0909$ ,  $\hat{\sigma}^2 = 165/242 = 0.6818$ .

11.30. Рассмотрим модель без константы. Тогда ковариационная матрица коэффициентов пропорциональна матрице

$$\begin{pmatrix} 1 & -\hat{\rho}_1 \\ -\hat{\rho}_1 & 1 \end{pmatrix}$$

11.31.

11.32.

11.33.

11.34.

11.35.

11.36.

11.37.

11.38. Процесс стационарен только при  $y_1 = 4 + \frac{2}{\sqrt{3}}\varepsilon_1$ . Фразу нужно понимать как «у стохастического разностного уравнения  $y_t = 2 + 0.5y_{t-1} + \varepsilon_t$  есть стационарное решение».

11.39.

1.  $\mathbb{E}(\varepsilon_t) = 0$ ,  $\text{Var}(\varepsilon_1) = \sigma^2$ ,  $\text{Var}(\varepsilon_t) = 2\sigma^2$  при  $t \geq 2$ . Гетероскедастичная.

2.  $\text{Cov}(e_t, e_{t+1}) = \sigma^2$ . Автокоррелированная.
3.  $\hat{\beta}$  — несмещенная, неэффективная
4. Более эффективной будет  $\hat{\beta}_{gls} = (X'V^{-1}X)^{-1}X'V^{-1}y$ , где

$$X = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

Матрица  $V$  известна с точностью до константы  $\sigma^2$ , но в формуле для  $\hat{\beta}_{gls}$  неизвестная  $\sigma^2$  сократится.

Другой способ построить эффективную оценку — применить МНК к преобразованным наблюдениям, т.е.  $\hat{\beta}_{gls} = \frac{\sum x'_i y'_i}{\sum x'^2_i}$ , где  $y'_1 = y_1$ ,  $x'_1 = x_1$ ,  $y'_t = y_t - y_{t-1}$ ,  $x'_t = x_t - x_{t-1}$  при  $t \geq 2$ .

12.1.

12.2.

12.3.  $f(x_1, x_2) = (x_1^2, x_2^2, \sqrt{2}x_1x_2)$ 

12.4.

12.5.

13.1.

13.2.

13.3.

14.1.

14.2.

14.3.

14.4.

14.5.

14.6.

14.7.

14.8.

14.9.

14.10.

14.11.

14.12.

14.13.

14.14. Например,  $A = (1, 2, 3)$ ,  $B = (1, 0, 1)'$ 14.15.  $\text{tr}(I) = n$ ,  $\text{tr}(\pi) = 1$ ,  $\text{tr}(P) = k$ 

14.16.

14.17.

14.18.  $n \times m$ ,  $m \times n$ ,  $I$ 

14.19.

14.20.

14.21.

15.1.

15.2.

15.3.

15.4.

15.5.

15.6.

15.7.

15.8.

15.9. По определению ковариационной матрицы:

$$\text{Var}(\xi) = \begin{pmatrix} \text{Var}(\xi_1) & \text{Cov}(\xi_1, \xi_2) & \text{Cov}(\xi_1, \xi_3) \\ \text{Cov}(\xi_2, \xi_1) & \text{Var}(\xi_2) & \text{Cov}(\xi_2, \xi_3) \\ \text{Cov}(\xi_3, \xi_1) & \text{Cov}(\xi_3, \xi_2) & \text{Var}(\xi_3) \end{pmatrix} = \begin{pmatrix} 2 & 1 & -1 \\ 1 & 3 & 0 \\ -1 & 0 & 4 \end{pmatrix}$$

$$\begin{aligned} \text{Var}(\xi_1 + \xi_2 + \xi_3) &= \text{Var} \left( \begin{pmatrix} 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} \xi_1 \\ \xi_2 \\ \xi_3 \end{pmatrix} \right) = \\ &= \begin{pmatrix} 1 & 1 & 1 \end{pmatrix} \text{Var} \begin{pmatrix} \xi_1 \\ \xi_2 \\ \xi_3 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \\ &= \begin{pmatrix} 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 2 & 1 & -1 \\ 1 & 3 & 0 \\ -1 & 0 & 4 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = 9 \quad (1.41) \end{aligned}$$

15.10.

$$\begin{aligned} \mathbb{E}(z_1) &= \mathbb{E} \left( \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \xi_1 \\ \xi_2 \end{pmatrix} \right) = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \mathbb{E} \begin{pmatrix} \xi_1 \\ \xi_2 \end{pmatrix} = \\ &= \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 2 \end{pmatrix} \quad (1.42) \end{aligned}$$

$$\begin{aligned} \text{Var}(z_1) &= \text{Var} \left( \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \xi_1 \\ \xi_2 \end{pmatrix} \right) = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \text{Var} \begin{pmatrix} \xi_1 \\ \xi_2 \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}^T = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}^T = \\ &= \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 0 & 2 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 2 \end{pmatrix} \end{aligned}$$

$$\begin{aligned} 15.11. \quad \mathbb{E}(z_2) &= \mathbb{E} \left( \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \xi_1 \\ \xi_2 \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right) = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \mathbb{E} \begin{pmatrix} \xi_1 \\ \xi_2 \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 2 \end{pmatrix} + \\ &+ \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 3 \end{pmatrix} \end{aligned}$$

Поскольку  $z_2 = z_1 + \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ , где  $z_1$  — случайный вектор из предыдущей задачи, то  $\text{Var}(z_2) = \text{Var}(z_1)$ . Сдвиг случайного вектора на вектор-константу не меняет его ковариационную матрицу.

15.12. В данном примере проиллюстрирована процедура центрирования случайного вектора — процедура вычитания из случайного вектора его математического ожидания.

$$\mathbb{E}(z_3) = \mathbb{E} \left( \begin{pmatrix} \xi_1 \\ \xi_2 \end{pmatrix} - \begin{pmatrix} \mathbb{E}\xi_1 \\ \mathbb{E}\xi_2 \end{pmatrix} \right) = \mathbb{E} \begin{pmatrix} \xi_1 \\ \xi_2 \end{pmatrix} - \mathbb{E} \begin{pmatrix} \mathbb{E}\xi_1 \\ \mathbb{E}\xi_2 \end{pmatrix} = \begin{pmatrix} \mathbb{E}\xi_1 \\ \mathbb{E}\xi_2 \end{pmatrix} - \begin{pmatrix} \mathbb{E}\xi_1 \\ \mathbb{E}\xi_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Заметим, что вектор  $z_3$  отличается от вектора  $z_1$  (из задачи 15) сдвигом на вектор-константу  $\begin{pmatrix} \mathbb{E}\xi_1 \\ \mathbb{E}\xi_2 \end{pmatrix}$ , поэтому  $\text{Var}(z_3) = \text{Var}(z_1)$ .

15.13.

15.14.

15.15.

15.16.

15.17. Каждый из вариантов возможен

15.18.

16.1.

16.2.

16.3.

16.4.

16.5.

16.6.

16.7.

16.8.

16.9.

16.10.

16.11. по  $\chi^2$ -распределению

16.12.  $u \sim N(0, I)$

17.1.

17.2.

17.3.

17.4.

17.5.

17.6.

17.7.

17.8.

17.9.

17.10.

17.11.

17.12.